

Detección y seguimiento de objetos desde perspectiva aérea mediante aprendizaje profundo

TT2026-2_IA05


Sergio de Jesús Castillo Molano
Miguel Alejandro Flores Sotelo

Instituto Politécnico Nacional
Unidad Profesional Interdisciplinaria de Ingeniería Campus Tlaxcala

2026



Introducción



Contexto

Los UAV permiten capturar imágenes y video desde perspectiva aérea para monitoreo, inspección, vigilancia, análisis de tráfico y búsqueda en zonas extensas o de difícil acceso.

Enfoque de IA

Se emplea aprendizaje profundo para localizar objetos, asignarles una clase, estimar una confianza y evaluar el desempeño mediante métricas de detección y eficiencia.

Base de IA del proyecto

El sistema se plantea como un pipeline de IA: análisis de datos UAV, preprocesamiento, entrenamiento de YOLOv8n y RT-DETR-L, evaluación por métricas y comparación de costo computacional.

Planteamiento del problema

Zoom a imagen más densa: 0000059_01886_d_0000114 (902 objetos totales)

Región central — sin anotaciones



Región central — con bboxes



Reto para la IA

- ▶ Objetos pequeños y variaciones de escala.
- ▶ Escenas densas, oclusiones y fondos complejos.
- ▶ Desbalance de clases y sesgo del dataset.
- ▶ Cambio de dominio entre VisDrone y UAVDT.
- ▶ Inestabilidad temporal al detectar cuadro por cuadro.

Problema central

Desarrollar y evaluar un sistema capaz de detectar y posteriormente seguir objetos en imágenes y videos UAV, reduciendo falsos positivos, falsos negativos y pérdida de identidad.

La perspectiva aérea modifica escala, ángulo, apariencia y densidad; por eso no se trata como detección convencional.

Objetivo general y alcance

Objetivo general

Desarrollar un sistema de detección de objetos desde perspectiva aérea mediante redes neuronales convolucionales y técnicas de visión por computadora.

Alcance de IA

El proyecto se concentra en construir un pipeline de visión por computadora y aprendizaje profundo para detectar objetos en imágenes aéreas: preparación de datos, aumento, entrenamiento, validación e interpretación de resultados.

Trabajo experimental

Se entrenan y comparan YOLOv8n y RT-DETR-L sobre VisDrone mediante mAP, precisión, recall, F1-score, matrices de confusión, desempeño por clase, latencia, FPS, parámetros, GFLOPs, VRAM y RAM.

Objetivos específicos

Datos y preparación

- ➊ **Análisis exploratorio:** caracterizar VisDrone y UAVDT por distribución de clases, desbalance y densidad de objetos por imagen.
- ➋ **Preprocesamiento y aumento:** normalizar imágenes y etiquetas; aplicar transformaciones geométricas, ajustes fotométricos, *mosaic* y *mixup*. Estas técnicas aumentan variabilidad, pero no eliminan el desbalance.

Modelos, tracking y evaluación

- ➌ **Detección:** implementar y entrenar YOLOv8n y RT-DETR sobre VisDrone, ajustando hiperparámetros y evaluando mAP@0.5, mAP@0.5:0.95, precisión, recall, F1-score e IoU.
- ➍ **Seguimiento temporal:** integrar *tracking-by-detection* y medir persistencia de identidad y falsas alarmas mediante MOTA e IDF1.
- ➎ **Comparación:** analizar el *trade-off* entre precisión y costo computacional con FPS, latencia, parámetros, GFLOPs, VRAM y RAM, además de validar generalización sobre UAVDT.

Justificación del proyecto

Práctica

UAV

Análisis automático de video aéreo

Técnica

IA

Evaluación de modelos de aprendizaje profundo

Aplicada

Edge AI

Base para despliegue embebido


Contribución

Pipeline experimental reproducible: análisis de datos aéreos, preprocesamiento, aumento de datos, entrenamiento de modelos, evaluación por clase, medición de eficiencia y preparación para seguimiento temporal.

Relevancia

El proyecto atiende retos vigentes de visión por computadora en UAV: objetos pequeños, escenas densas, desbalance de clases, cambio de dominio y restricciones de cómputo para una posible implementación en Edge AI.

Propuesta de solución




Idea principal

El sistema se plantea como un pipeline reproducible: entrada aérea, preparación de datos, entrenamiento supervisado, evaluación cuantitativa y futura integración temporal.

Salida esperada

Cada detección debe producir clase, caja delimitadora, confianza y evidencia visual. En etapas posteriores se agregará ID de trayectoria, marca temporal y posible georreferenciación para registrar eventos útiles.

Diagrama metodológico



Fundamento IA: detección de objetos



Clasificación

¿Qué es?

Clase del objeto

Localización

¿Dónde está?

Caja delimitadora

Confianza

¿Qué tan seguro?

Probabilidad estimada

Modelos evaluados

YOLOv8n

- ▶ Detector de una etapa
- ▶ Arquitectura ligera
- ▶ Línea base eficiente

RT-DETR-L

- ▶ Arquitectura CNN + Transformer
- ▶ Mayor capacidad de representación
- ▶ Comparación directa contra YOLOv8n

Pregunta experimental: ¿más precisión justifica mayor costo computacional?


Conjuntos de datos

Dataset	Uso en el proyecto	Razón
VisDrone-DET2019	Entrenamiento y evaluación principal	Diez clases en imágenes reales capturadas desde drones
UAVDT	Validación cruzada futura	Dominio aéreo distinto con clases vehiculares compartidas

Punto crítico

Un dataset específico puede inducir sesgo por distribución de clases, condiciones de captura y frecuencia de objetos.

Análisis exploratorio de VisDrone



Detecciones válidas

343,171

split de entrenamiento

Clase dominante

42.21 %

car



Objetos pequeños

60.47 %

criterio COCO

Preprocesamiento y aumento de datos

Verificación de conversión — Labels YOLO sobre imágenes VisDrone



Conversión de etiquetas

`class_id, x, y, width, height`

Aumento de datos

- ▶ Mosaic, mixup y HSV
- ▶ Escalado, traslación y volteo
- ▶ Mayor variabilidad visual

Nota: no elimina el desbalance; ayuda a generalizar.

Configuración experimental

Parámetro	YOLOv8n	RT-DETR-L
Pesos iniciales	COCO	COCO
Épocas	100	100
Tamaño imagen	1280	1280
Batch	4	4
Optimizador	AdamW	AdamW
Precisión	FP16	AMP
Mosaic	1.0	1.0
close_mosaic	10	10

Enfoque IA

- ▶ Transferencia de aprendizaje
- ▶ Mismo dominio: VisDrone
- ▶ Comparación controlada

Resultados globales de detección

Métrica	YOLOv8n	RT-DETR-L
mAP@0.5	0.4755	0.5114
mAP@0.5:0.95	0.2874	0.3166
Precisión	0.5944	0.6433
Recall	0.4641	0.5332
F1-score	0.5212	0.5831


Lectura

RT-DETR-L mejora las métricas globales, pero con mayor costo computacional.

Matrices de confusión normalizadas


YOLOv8n

Confusion Matrix Normalized




RT-DETR-L

Confusion Matrix Normalized




Aprendizaje por clase

YOLOv8n



RT-DETR-L



Comparación: precisión vs. costo computacional

Modelo	mAP@0.5	F1	GFLOPs	Latencia	FPS	VRAM	RAM
YOLOv8n	0.4755	0.5212	8.20	5.95 ms	167.98	72.8 MB	1187.1 MB
RT-DETR-L	0.5114	0.5831	108.03	94.14 ms	10.62	463.9 MB	1361.5 MB

Medición sobre 1,610 imágenes, tamaño 1280 px, GPU NVIDIA GeForce RTX 4050 Laptop.

Mejora RT-DETR-L

+0.0359

mAP@0.5 frente a YOLOv8n

Costo RT-DETR-L

≈15.8x

latencia frente a YOLOv8n

Interpretación

RT-DETR-L mejora la precisión; YOLOv8n conserva mayor viabilidad para inferencia en tiempo real.

Comparación con YOLOv8n

Trabajo / modelo	Base reportada	P	R	F1	mAP50	mAP50-95	FPS
YOLOv8-N (RTUAV-YOLO, 2025)	YOLOv8-N	42.5	33.9	—	33.3	19.6	184
YOLOv8n (YOLO-MARS, 2025)	YOLOv8n	43.6	32.9	—	32.8	19.1	—
YOLO-MARS (2025)	YOLOv8n mejorado	50.2	40.0	—	40.9	23.4	—
MASW-YOLO (2025)	YOLOv8n mejorado	54.3	32.7	—	38.3	24.5	107.5
Improved YOLOv8n (2024)	YOLOv8n mejorado	47.1	37.4	—	37.6	—	—
Nuestro YOLOv8n	YOLOv8n / Ultralytics	59.44	46.41	52.12	47.55	28.74	167.98

Comparación con RT-DETR

Trabajo / modelo		Base reportada	P	R	F1	mAP50	mAP50-95	FPS
RT-DETR-R18	(Drone-DETR, 2024)	RT-DETR-R18	–	–	–	45.8	27.7	76
RT-DETR-R50	(RTUAV-YOLO, 2025)	RT-DETR-R50	–	–	–	48.3	28.8	69
Drone-DETR (2024)		RT-DETR mejorado	–	–	–	53.9	33.9	30
RTUAV-YOLO-X (2025)		YOLO UAV SOTA	61.3	48.1	–	51.4	32.4	65
DV-DETR (2024)		RT-DETR mejorado	62.43	47.76	–	50.05	31.40	90
Nuestro RT-DETR-L		RT-DETR-L / Ultralytics	64.33	53.32	58.31	51.14	31.66	10.62

Cronograma de actividades

Actividad	Periodo	Estado	Evidencia
EDA VisDrone/UAVDT	Mar–Abr	Completada	Gráficas, distribución y densidad
Preprocesamiento y aumento	May–Jun	Completada	Etiquetas YOLO y verificación visual
YOLOv8n + RT-DETR-L	Jun–Ago	Completada	Métricas, curvas y costo computacional
Seguimiento multiobjeto	Jul–Ago	Pendiente	DeepSORT / ByteTrack
Validación cruzada UAVDT	Sep–Oct	Pendiente	Análisis de <i>domain shift</i>
Pipeline y Jetson Orin Nano	Oct–Nov	Pendiente	Inferencia embebida y registros

Trabajo pendiente

Las siguientes actividades son integrar seguimiento multiobjeto, validar la generalización sobre UAVDT, construir el pipeline final y medir desempeño en Jetson Orin Nano con enfoque de cómputo embebido.

Conclusiones y trabajo pendiente

Conclusiones

- ▶ El dominio UAV presenta alta dificultad visual.
- ▶ YOLOv8n es eficiente; RT-DETR-L es más preciso.
- ▶ El desempeño depende del dataset, tamaño de objeto y costo computacional.

Siguientes etapas

- ▶ UAVDT
- ▶ DeepSORT / ByteTrack
- ▶ Jetson Orin Nano

Referencias

- ▶ YOLO-MARS (2025). YOLOv8n mejorado sobre VisDrone2019. Sensors
- ▶ MASW-YOLO (2025). Modelo basado en YOLOv8n para objetos pequeños UAV. Scientific Reports
- ▶ Improved YOLOv8n (2024). Detección de objetos pequeños en imágenes UAV. Springer
- ▶ RTUAV-YOLO (2025). Comparación YOLOv8-N, RT-DETR y modelos UAV. Sensors
- ▶ Drone-DETR (2024). Modelo mejorado basado en RT-DETR. Sensors PDF
- ▶ DV-DETR (2024). Detector basado en RT-DETR para VisDrone. PDF
- ▶ Ultralytics. Documentación de VisDrone y RT-DETR. VisDrone / RT-DETR

Gracias

Sergio de Jesús Castillo Molano
Miguel Alejandro Flores Sotelo

TT2026-2_IA05