



Detección de objetos desde perspectiva aérea mediante redes neuronales convolucionales y técnicas de visión por computadora

Alumnos: Miguel Alejandro Flores Sotelo, Sergio de Jesús Castillo Molano

Directores: Gerardo Taxis Taxis, Alfredo Roldán Caballero

gtexist@ipn.mx
aroldanc@ipn.mx
scastillom2200@alumno.ipn.mx
mfloress2200@alumno.ipn.mx

Trabajo Terminal No. TT2026-2_IA05
Instituto Politécnico Nacional
April 17, 2026

Abstract

Este Trabajo Terminal propone el desarrollo de un sistema de visión por computadora basado en técnicas de aprendizaje profundo para la detección y seguimiento de objetos en imágenes y secuencias de video capturadas desde perspectiva aérea mediante vehículos aéreos no tripulados (UAV). El sistema se entrena y evalúa sobre el conjunto de datos VisDrone, que comprende imágenes aéreas reales con diez categorías de objetos (peatones, ciclistas, vehículos de distintas categorías, entre otros) bajo condiciones de alta densidad, oclusión parcial y objetos de tamaño reducido. Para analizar la capacidad de generalización, se realiza una evaluación complementaria sobre el conjunto UAVDT, cuyas clases (automóvil, camión y autobús) constituyen un subconjunto de las categorías de VisDrone, permitiendo medir la transferencia del modelo a un dominio aéreo distinto.

El problema considera retos característicos de operación en escenarios reales: objetos que ocupan una fracción reducida del encuadre, variaciones de escala por cambios de altitud, fondos heterogéneos, cambios de iluminación, oclusiones parciales y degradación por movimiento de la plataforma. Para enfrentarlos, se comparan dos arquitecturas de detección YOLOv8n, orientada a eficiencia en Edge AI, y RT-DETR, orientada a precisión analizando el compromiso entre exactitud y costo computacional. La detección se complementa con un módulo de seguimiento temporal (*tracking-by-detection*) para mantener la persistencia de identidad entre cuadros y reducir falsas alarmas.

El sistema se evalúa mediante métricas estándar de detección (mAP@0.5, mAP@0.5:0.95, precisión, recall e IoU) y métricas de seguimiento multi-objeto (MOTA, IDF1).

Palabras clave: Visión por computadora, redes neuronales convolucionales, detección de objetos, UAV, análisis de video, Edge AI.



1 Introducción

La percepción visual desde plataformas aéreas es una herramienta relevante para inspección, monitoreo y apoyo a tareas de búsqueda en entornos abiertos, al permitir cubrir grandes superficies desde una perspectiva elevada. En este contexto, la detección de objetos mediante visión artificial en secuencias de video UAV permite identificar objetivos de interés de forma automática [1, 2].

Sin embargo, la visión aérea incrementa la complejidad del problema: los objetivos suelen ocupar pocos píxeles (*small objects*), existe variación continua de escala por cambios de altitud y distancia, y el fondo es heterogéneo. Además, cambios de iluminación, oclusiones parciales y degradaciones por movimiento (desenfoque y vibración) afectan la generalización y aumentan falsos positivos y falsos negativos [1, 2].

En términos de IA, la detección moderna se apoya en arquitecturas de aprendizaje profundo, empleando detectores *one-stage* (p. ej., YOLO, SSD) por eficiencia y *two-stage* (p. ej., Faster R-CNN) cuando se prioriza exactitud [3, 4, 5]. Recientemente, modelos híbridos como RT-DETR combinan un backbone CNN con un decoder basado en Transformers, logrando mayor precisión manteniendo velocidad de inferencia competitiva [6]. En video, para reducir inestabilidad cuadro a cuadro, se integran esquemas de *tracking-by-detection* como SORT/DeepSORT y reglas de verificación temporal [7, 8]. Finalmente, para que los resultados sean operativamente útiles, se requiere registrar eventos y asociarlos con información espacial mediante georreferenciación a partir de datos de navegación y parámetros de cámara [9].

En este contexto, el presente trabajo propone un enfoque de visión artificial basado en técnicas de aprendizaje profundo para detección y seguimiento de objetos desde perspectiva aérea.

2 Objetivos

2.1 Objetivo general

Desarrollar un sistema de detección de objetos desde perspectiva aérea mediante redes neuronales convolucionales y técnicas de visión por computadora.

2.2 Objetivos específicos

- Realizar un análisis exploratorio de los conjuntos de datos VisDrone y UAVDT, caracterizando la distribución de clases, el desbalance y la densidad de objetos por imagen, con el fin de identificar los retos específicos de cada conjunto para el entrenamiento y la evaluación.
- Diseñar e implementar una estrategia de preprocesamiento y aumento de datos que mitigue el desbalance de clases e incremente la variabilidad visual del conjunto de entrenamiento, mediante normalización de imágenes y etiquetas, transformaciones geométricas (rotación, escalado, recorte y flip), ajustes fotométricos (HSV jitter, brillo y contraste), y técnicas avanzadas de augmentation (mosaic, mixup y copy-paste dirigido a clases minoritarias).
- Implementar y entrenar dos arquitecturas de detección de objetos YOLOv8n y RT-DETR sobre el conjunto VisDrone, ajustando hiperparámetros y midiendo el desempeño de cada arquitectura mediante mAP@0.5, mAP@0.5:0.95, precisión, recall e IoU.



- Integrar un módulo de seguimiento temporal (*tracking-by-detection*) al pipeline de detección, cuantificando su contribución a la persistencia de identidad y a la reducción de falsas alarmas en secuencias de video mediante métricas multi-objeto (MOTA e IDF1).
- Comparar el trade-off entre precisión y eficiencia computacional (FPS, latencia) de las arquitecturas entrenadas, y validar la generalización del modelo con mejor desempeño sobre el conjunto UAVDT, cuantificando su capacidad de transferencia a un dominio aéreo distinto al de entrenamiento.

3 Planteamiento del problema

El avance de la visión por computadora basada en aprendizaje profundo ha permitido desarrollar modelos capaces de detectar objetos con altos niveles de precisión en imágenes convencionales [3, 5]. Sin embargo, cuando estos modelos se aplican en escenarios de perspectiva aérea mediante UAV, emergen desafíos específicos que afectan su desempeño y robustez, y que constituyen un problema activo de investigación en la comunidad de visión por computadora [1, 10].

Desde una perspectiva computacional, los retos del dominio aéreo se manifiestan en tres niveles. Primero, a nivel de representación: los objetos de interés suelen ocupar entre 10 y 50 píxeles en el encuadre (*small objects*), lo que reduce drásticamente la información disponible para el extractor de características y degrada la capacidad discriminativa de los modelos [10, 2]. Segundo, a nivel de distribución de datos: los conjuntos de entrenamiento presentan desbalance severo de clases y alta variabilidad visual por cambios de altitud, iluminación y movimiento de la plataforma, generando una brecha (*domain shift*) entre los datos de entrenamiento y los escenarios reales de operación [1, 11]. Tercero, a nivel de inferencia temporal: la detección independiente por frame no garantiza consistencia en secuencias de video, incrementando falsos positivos y pérdida de objetivos, lo que hace necesaria la integración de mecanismos de seguimiento temporal [7, 12].

En consecuencia, el problema central consiste en desarrollar y evaluar un pipeline computacional que integre detección basada en aprendizaje profundo y seguimiento temporal, capaz de operar de forma robusta ante las condiciones propias de la perspectiva aérea, y cuyo desempeño sea medible y comparable con el estado del arte mediante métricas estándar del dominio [1, 2, 11].

4 Justificación

La pertinencia de este trabajo radica en que la detección y seguimiento automático de objetos desde plataformas UAV puede contribuir de manera directa a mejorar tareas de monitoreo, inspección y búsqueda en entornos extensos o de difícil acceso, donde la revisión manual de imágenes y secuencias de video resulta lenta, demandante y propensa a omisiones derivadas de la fatiga del operador [13, 14]. En este sentido, desarrollar un sistema capaz de identificar objetos de interés, mantener su seguimiento en el tiempo y registrar su localización de forma estructurada representa una alternativa con valor práctico, ya que permitiría reducir la carga operativa, agilizar el análisis de la información visual y generar evidencia útil para apoyar la toma de decisiones en escenarios donde la oportunidad de respuesta es un factor relevante [15, 9].



Asimismo, el proyecto se justifica en el ámbito académico y tecnológico porque aborda problemas que continúan siendo un reto para la visión por computadora aplicada a entornos aéreos, tales como la detección de objetos pequeños, la variación entre dominios, el desbalance de clases y las restricciones de cómputo en plataformas de Edge AI [1, 10, 16]. Atender estos desafíos mediante una metodología que combine preprocesamiento, comparación de arquitecturas de aprendizaje profundo y seguimiento temporal no solo permitirá evaluar la viabilidad de una solución robusta para este tipo de escenarios, sino también aportar evidencia experimental sobre el comportamiento y las limitaciones de estas técnicas en condiciones propias del dominio UAV. De esta manera, el trabajo encuentra su justificación tanto por su utilidad potencial en aplicaciones reales como por su contribución al análisis de problemas vigentes dentro de la investigación en visión por computadora.

5 Trabajos relacionados (Estado del arte)

La detección y el seguimiento de objetos desde perspectiva aérea se han estudiado ampliamente y los surveys recientes coinciden en que los principales retos del dominio UAV son los *small objects*, la variación de escala por altitud, fondos complejos, cambios de iluminación, oclusión y desenfoque por movimiento, lo que incrementa el *domain shift* y afecta la generalización [1, 17, 10]. Como referencia de evaluación, VisDrone y su challenge VisDrone-DET2019 consolidan un benchmark para detección en imágenes de dron y evidencian la dificultad del problema en escenas densas con oclusión y objetos pequeños bajo métricas tipo COCO (AP promedio en IoU 0.50–0.95) [2, 18].

En enfoques clásicos, Ibáñez (2015) aborda videovigilancia aérea separando el movimiento global de cámara del movimiento real mediante alineamiento y flujo óptico, incorporando filtro de Kalman para estabilizar trayectorias [19]. En integración visión-geoespacial, Božić-Štulić et al. (2018) proponen un pipeline que incluye planeación de ruta, mosaicking, georreferenciación y detección con CNN sobre teselas del mosaico, conectando detección con productos geoespaciales [15].

En detección con aprendizaje profundo, predominan detectores *one-stage* y *two-stage*: YOLO y SSD se emplean por eficiencia, mientras que Faster R-CNN es una base sólida cuando se prioriza exactitud; la literatura destaca la necesidad de estrategias multi-escala y ajustes específicos para UAV para mitigar degradación por escala, iluminación y oclusión [3, 4, 5, 1]. Para video, el *tracking-by-detection* es una línea central: SORT y DeepSORT son referentes por su combinación de predicción (Kalman) y asociación, y ByteTrack mejora robustez al asociar detecciones de baja confianza [7, 8, 12]. En seguimiento aéreo, trabajos clásicos y de evaluación resaltan la importancia de compensación de movimiento y la dificultad por oclusión/escala/iluminación: COCOA modela un pipeline por etapas para imágenes aéreas [20], Salti et al. comparan rastreadores adaptativos destacando TLD/STRUCK en condiciones difíciles [21], y Malagi et al. proponen ATLD como adaptación de TLD para secuencias aéreas [22, 23]. Además, Nussberger et al. muestran que en escenarios adversos (clutter, nubes, *lens flares*) se requieren módulos explícitos de robustez y verificación de trayectorias [24, 25]; de manera complementaria, UAVDT estandariza evaluación en video UAV para detección y tracking (DET/SOT/MOT) con atributos como oclusión e iluminación [11].

En aplicaciones SAR, Ramírez-Ayala et al. (2023) estudian detección humana en zonas boscosas con imágenes térmicas y una verificación con CNN para reducir falsos positivos bajo oclusión [26], mientras que Ciccone y Ceruti (2025) optimizan YOLO para *small objects* con transferencia en dos etapas (VisDrone + dataset SAR), explorando mejoras multi-escala y atención [13]. En el compo-



nente geoespacial, ORB-SLAM representa una base para estimación de pose y mapeo visual [27], y se han propuesto métodos de georreferenciación directa en UAS basados en modelo geométrico de cámara y navegación [28]. Además, existen enfoques de geo-localización con deep learning: Cabrera-Ponce y Martínez-Carranza estiman coordenadas desde una sola imagen aérea [29], PoseNet y extensiones incorporan pérdidas geométricas y temporalidad para regresión de pose [30, 31, 32], y Nassar et al. plantean registro UAV-satélite con segmentación semántica para escenarios *GPS-denied* [33]. Como cierre aplicado, Alonso Rodríguez discute retos prácticos en exteriores (escala, perspectiva, oclusión e iluminación) y Rahman et al. revisan datasets UAV y su impacto en generalización [14, 16]. En conjunto, estos trabajos respaldan que una solución robusta en entornos abiertos desde perspectiva aérea debe integrar detección basada en CNN, seguimiento temporal para estabilidad y reducción de falsas alarmas, y georreferenciación para convertir detecciones en eventos con utilidad operativa.

6 Resultados Esperados

Como resultado principal se espera obtener un pipeline funcional de detección y seguimiento de objetos desde perspectiva aérea, entrenado sobre VisDrone y con generalización verificada sobre UAVDT. La Tabla 1 resume las métricas objetivo por componente del sistema, tomando como referencia resultados reportados en la literatura para estas arquitecturas sobre el benchmark VisDrone [2, 12, 13].

Tabla 1: Métricas esperadas por componente del sistema

Componente	Métrica	Valor esperado	Arquitectura
Detección	mAP@0.5	$\geq 30\%$	YOLOv8n
Detección	mAP@0.5	$\geq 40\%$	RT-DETR
Detección	mAP@0.5:0.95	$\geq 18\%$	YOLOv8n
Detección	mAP@0.5:0.95	$\geq 25\%$	RT-DETR
Detección	FPS	≥ 30	YOLOv8n
Detección	FPS	≥ 15	RT-DETR
Seguimiento	MOTA	$\geq 40\%$	Pipeline completo
Seguimiento	IDF1	$\geq 45\%$	Pipeline completo
Generalización	mAP@0.5 (UAVDT)	Degradación $< 10\%$	Mejor modelo

Se anticipa que RT-DETR supere a YOLOv8n en precisión (mAP@0.5:0.95) mientras que YOLOv8n presente ventaja en eficiencia computacional, evidenciando el compromiso entre precisión y velocidad de inferencia para aplicaciones de visión aérea. La integración del módulo de seguimiento temporal se espera que reduzca las falsas alarmas respecto a la detección por frame individual, mejorando la consistencia de identidad en secuencias de video.

7 Metodología

Se estructura en fases que permiten desarrollar, integrar y validar un sistema de detección y seguimiento de objetos desde perspectiva aérea, basado en técnicas de aprendizaje profundo. El



flujo de trabajo contempla desde la preparación y análisis de los datos hasta la evaluación experimental del sistema y su validación en un dominio aéreo distinto al de entrenamiento.

7.1 Fase 1. Preparación y análisis del conjunto de datos

Se utilizan dos conjuntos de datos para perspectiva aérea: VisDrone como conjunto principal de entrenamiento y evaluación, y UAVDT como conjunto de validación cruzada para análisis de generalización.

VisDrone-DET2019 comprende 10,209 imágenes estáticas y 288 secuencias de video capturadas desde UAV, con anotaciones para 10 categorías de objetos (peatón, persona, bicicleta, automóvil, van, camión, triciclo, triciclo con toldo, autobús y motocicleta). Este conjunto presenta desbalance severo de clases, las categorías de vehículos como automóvil dominan el conjunto mientras que categorías como triciclo con toldo tienen representación mínima, así como alta proporción de *small objects* (objetos que ocupan menos de 32×32 píxeles) y escenas de alta densidad con oclusión frecuente.

UAVDT comprende 80,000 frames de video con anotaciones para 3 categorías (automóvil, camión y autobús), que constituyen un subconjunto directo de las categorías de VisDrone, permitiendo evaluación cruzada sin necesidad de reentrenamiento.

Se realiza un análisis exploratorio de ambos conjuntos que incluye: distribución de clases e identificación del desbalance, distribución de tamaños de objeto (*small, medium, large* según criterios COCO), densidad de objetos por imagen, y variabilidad visual por condiciones de iluminación y altitud. Para mitigar el desbalance de clases en VisDrone se aplican las siguientes estrategias: sobremuestreo de clases minoritarias mediante duplicación y transformaciones aleatorias, ponderación de clases en la función de pérdida (*class weighting*), y aumento de datos con técnicas de *mosaic augmentation*, variaciones de iluminación, cambios de escala y orientación, y simulación de desenfoque por movimiento.

7.2 Fase 2. Diseño, entrenamiento y ajuste del modelo de detección

Se implementan y entrenan dos arquitecturas de detección de objetos con enfoques complementarios. YOLOv8n representa el enfoque *one-stage* orientado a eficiencia computacional, con aproximadamente 3.2 millones de parámetros y diseño optimizado para Edge AI. RT-DETR representa el enfoque híbrido CNN-Transformer orientado a precisión, con un backbone ResNet y un decoder basado en atención que elimina la necesidad de NMS (*Non-Maximum Suppression*).

Ambas arquitecturas se entrenan sobre el conjunto VisDrone-DET2019, ajustando hiperparámetros mediante validación cruzada. Se mide el desempeño de cada arquitectura mediante métricas estándar: mAP@0.5, mAP@0.5:0.95, precisión, recall e IoU promedio. Se registran además los indicadores de eficiencia computacional (FPS y latencia) para cada arquitectura, con el fin de analizar el compromiso entre exactitud y costo de inferencia.

7.3 Fase 3. Modelado temporal y desarrollo del módulo de seguimiento

Se integra un módulo de seguimiento temporal basado en el paradigma *tracking-by-detection*, que asocia detecciones entre cuadros consecutivos mediante predicción de movimiento y métricas de



similitud. Se evalúan dos enfoques: DeepSORT, que combina filtro de Kalman para predicción cinemática con características visuales profundas para asociación, y ByteTrack, que mejora la robustez al asociar tanto detecciones de alta como de baja confianza.

La evaluación se realiza sobre secuencias de video de VisDrone mediante métricas estándar de seguimiento multi-objeto: MOTA (*Multiple Object Tracking Accuracy*), que cuantifica falsos positivos, objetos perdidos y cambios de identidad; e IDF1 (*Identity F1 Score*), que mide la consistencia de identidad a lo largo de las trayectorias. Se cuantifica la contribución del módulo de tracking a la persistencia de identidad y a la reducción de falsas alarmas respecto a la detección por frame individual.

7.4 Fase 4. Comparación de arquitecturas y evaluación de generalización

Se comparan las arquitecturas YOLOv8n y RT-DETR en términos de precisión (mAP@0.5, mAP@0.5:0.95) y eficiencia computacional (FPS, latencia), estableciendo el compromiso entre ambos enfoques para aplicaciones de visión aérea. Se determina la arquitectura con mejor desempeño global considerando ambas dimensiones.

Adicionalmente, se evalúa la capacidad de generalización del modelo con mejor desempeño mediante validación cruzada sobre el conjunto UAVDT, cuantificando la degradación de métricas al transferir el modelo entrenado en VisDrone a un dominio aéreo distinto. Las condiciones evaluadas incluyen: diferentes condiciones de iluminación (luz diurna, contraluz y baja iluminación), y escenas con densidad variable de objetos y oclusión parcial, analizando el impacto del *domain shift* en el desempeño del sistema.

7.5 Fase 5. Integración del pipeline y registro de eventos

Se integra el pipeline completo de detección y seguimiento en un sistema funcional de extremo a extremo. El sistema genera registros estructurados por evento que incluyen: clase del objeto detectado, nivel de confianza, identificador de trayectoria asignado por el tracker y marca temporal. Como complemento, se incorpora una estimación de ubicación georreferenciada a partir del modelo geométrico de la cámara y los datos de navegación del UAV (GPS y orientación), habilitando la visualización espacial de los eventos detectados durante el vuelo.




Figura 1: Flujo de la metodología.



8 Cronograma de Actividades

Tabla 2: Cronograma de actividades

No.	Actividad	FEB	MAR	ABR	MAY	JUN	JUL	AGO	SEP	OCT	NOV	DIC
1	Escritura del documento terminal (redacción, revisión y ajuste de secciones)											
2	Análisis exploratorio de los conjuntos de datos VisDrone y UAVDT (distribución de clases, desbalance, densidad y tamaños de objeto)											
3	Preprocesamiento y aumento de datos (normalización de imágenes y etiquetas, transformaciones geométricas, ajustes fotométricos, <i>mosaic</i> , <i>mixup</i> y <i>copy-paste</i> dirigido a clases minoritarias)											
4	Implementación y entrenamiento de YOLOv8n y RT-DETR sobre VisDrone (ajuste de hiperparámetros y evaluación con mAP@0.5, mAP@0.5:0.95, precisión, recall e IoU)											
5	Desarrollo e integración del módulo de seguimiento temporal (DeepSORT / ByteTrack) y evaluación con métricas MOT (MOTA e IDF1) sobre secuencias de video VisDrone											
6	Comparación del trade-off precisión/eficiencia computacional (FPS, latencia) entre YOLOv8n y RT-DETR											
7	Validación cruzada sobre UAVDT y análisis de <i>domain shift</i> (degradación de métricas al transferir el modelo a un dominio aéreo distinto)											
8	Integración del pipeline completo y generación de registros estructurados de eventos (clase, confianza, ID de trayectoria, marca temporal y georreferenciación)											
9	Ajustes finales, revisión integral del sistema y preparación de la presentación de resultados											

9 Conclusiones

El presente protocolo propone un sistema de detección y seguimiento de objetos desde perspectiva aérea que aborda retos computacionales activos del dominio UAV: *small objects*, desbalance de clases, *domain shift* y consistencia temporal en secuencias de video. A diferencia de enfoques que tratan estos problemas de forma aislada, la propuesta los integra en un pipeline coherente que cubre desde el análisis y preprocesamiento de datos hasta la evaluación experimental con métricas estándar del estado del arte.

Desde el punto de vista algorítmico, la comparación entre YOLOv8n y RT-DETR permite analizar el compromiso entre precisión y eficiencia computacional en un dominio exigente como



VisDrone, mientras que la validación cruzada sobre UAVDT aporta evidencia sobre la capacidad de generalización del sistema a dominios aéreos distintos al de entrenamiento. La integración del módulo de seguimiento temporal mediante métricas MOT (MOTA e IDF1) añade una dimensión de evaluación que va más allá de la detección por frame individual, acercando el sistema a condiciones de operación real.

En conjunto, el proyecto contribuye al desarrollo de soluciones de visión artificial aplicadas a UAV, aportando evidencia técnica y reproducible sobre la viabilidad y limitaciones de estos enfoques en escenarios abiertos desde perspectiva aérea.

Referencias

- [1] G. Tang, J. Ni, Y. Zhao, Y. Gu, and W. Cao, “A survey of object detection for uavs based on deep learning,” *Remote Sensing*, vol. 16, no. 1, p. 149, 2024.
- [2] D. Du, P. Zhu, L. Wen, X. Bian, H. Lin, Q. Hu, T. Peng, J. Zheng, X. Wang, Y. Zhang, L. Bo, H. Shi, R. Zhu *et al.*, “Visdrone-det2019: The vision meets drone object detection in image challenge results,” in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV) Workshops*, Oct. 2019, pp. 213–226.
- [3] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, “You only look once: Unified, real-time object detection,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 779–788.
- [4] W. Liu, D. Anguelov, D. Erhan, C. Szegedy, S. Reed, C.-Y. Fu, and A. C. Berg, “Ssd: Single shot multibox detector,” in *European Conference on Computer Vision (ECCV)*, 2016.
- [5] S. Ren, K. He, R. Girshick, and J. Sun, “Faster r-cnn: Towards real-time object detection with region proposal networks,” *arXiv preprint arXiv:1506.01497*, 2015.
- [6] Y. Zhao, W. Lv, S. Xu, J. Wei, G. Wang, Q. Deng, C. Bacea, and Y. Liu, “Detrs beat yolos on real-time object detection,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2024, pp. 16 965–16 974.
- [7] A. Bewley, Z. Ge, L. Ott, F. Ramos, and B. Upcroft, “Simple online and realtime tracking,” *arXiv preprint arXiv:1602.00763*, 2016.
- [8] N. Wojke, A. Bewley, and D. Paulus, “Simple online and realtime tracking with a deep association metric,” *arXiv preprint arXiv:1703.07402*, 2017.
- [9] S. Sambolek and M. Ivašić-Kos, “Person detection and geolocation estimation in uav aerial images: An experimental approach,” in *Proceedings of the 13th International Conference on Pattern Recognition Applications and Methods (ICPRAM 2024)*. SCITEPRESS, 2024, pp. 785–792.
- [10] W. Hua *et al.*, “A survey of small object detection based on deep learning in aerial images,” *Artificial Intelligence Review*, 2025.



-
- [11] D. Du, Y. Qi, H. Yu, Y. Yang, K. Duan, G. Li, W. Zhang, Q. Huang, and Q. Tian, "The unmanned aerial vehicle benchmark: Object detection and tracking," in *European Conference on Computer Vision (ECCV)*, 2018.
 - [12] Y. Zhang, P. Sun, Y. Jiang, D. Yu, F. Weng, Z. Yuan, P. Luo, W. Liu, and X. Wang, "Bytetrack: Multi-object tracking by associating every detection box," in *European Conference on Computer Vision (ECCV)*, 2022.
 - [13] F. Ciccone and A. Ceruti, "Real-time search and rescue with drones: A deep learning approach for small-object detection based on yolo," *Drones*, vol. 9, no. 8, p. 514, 2025.
 - [14] A. Alonso Rodríguez, "Utilización de drones para detección y seguimiento de personas y objetos en entornos de exteriores," 2025, trabajo Fin de Grado.
 - [15] D. Božić-Štulić, S. Kružić, S. Gotovac, and V. Papić, "Complete model for automatic object detection and localisation on aerial images using convolutional neural networks," *Journal of Communications Software and Systems*, vol. 14, no. 1, 2018.
 - [16] M. M. Rahman, S. Siddique, M. Kamal, R. H. Rifat, and K. D. Gupta, "Uav (unmanned aerial vehicle): Diverse applications of uav datasets in segmentation, classification, detection, and tracking," *Algorithms*, vol. 17, p. 594, 2024.
 - [17] G. Tang, J. Ni, Y. Zhao, Y. Gu, and W. Cao, "A survey of object detection for uavs based on deep learning," *Remote Sensing*, vol. 16, no. 1, p. 149, 2024.
 - [18] D. Du, P. Zhu, L. Wen, X. Bian *et al.*, "Visdrone-det2019: The vision meets drone object detection in image challenge results," in *ICCV Workshops*, 2019.
 - [19] N. Ibáñez Sáez, "Técnicas de procesamiento de imagen para el seguimiento de objetos desde vehículos aéreos no tripulados," 2015, trabajo Fin de Grado.
 - [20] S. Ali and M. Shah, "Cocoa: Tracking in aerial imagery," in *Proceedings of SPIE 6209, Ground/Air Multisensor Interoperability, Integration, and Networking for Persistent ISR VII*, 2006, p. 62090D.
 - [21] S. Salti, A. Cavallaro, and L. Di Stefano, "Adaptive appearance modeling for video tracking: Survey and evaluation," *IEEE Transactions on Image Processing*, vol. 21, no. 10, pp. 4334–4348, 2012.
 - [22] V. P. Malagi, R. D. R. Babu, and K. Rangarajan, "Multi-object tracking in aerial image sequences using aerial tracking learning and detection algorithm," *Defence Science Journal*, vol. 66, no. 2, pp. 122–129, 2016.
 - [23] Z. Kalal, K. Mikolajczyk, and J. Matas, "Tracking-learning-detection," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 34, no. 7, pp. 1409–1422, 2012.
 - [24] A. Nussberger, H. Grabner, and L. Van Gool, "Aerial object tracking from an airborne platform," in *International Conference on Unmanned Aircraft Systems (ICUAS)*, 2014.
-



-
- [25] —, “Robust aerial object tracking from an airborne platform,” *IEEE Aerospace and Electronic Systems Magazine*, 2016.
 - [26] O. Ramírez-Ayala, I. González-Hernández, S. Salazar, J. Flores, and R. Lozano, “Real-time person detection in wooded areas using thermal images from an aerial perspective,” *Sensors*, vol. 23, no. 22, p. 9216, 2023.
 - [27] R. Mur-Artal, J. M. M. Montiel, and J. D. Tardós, “Orb-slam: A versatile and accurate monocular slam system,” *IEEE Transactions on Robotics*, vol. 31, no. 5, pp. 1147–1163, 2015.
 - [28] C. A. M. Correia *et al.*, “Comprehensive direct georeferencing of aerial images acquired by cameras mounted on uas,” *Sensors*, vol. 22, no. 2, p. 604, 2022.
 - [29] A. A. Cabrera-Ponce and J. Martínez-Carranza, “Convolutional neural networks for geolocalisation with a single aerial image,” *Journal of Real-Time Image Processing*, 2022.
 - [30] A. Kendall, M. Grimes, and R. Cipolla, “Posenet: A convolutional network for real-time 6-dof camera relocalization,” in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2015, pp. 2938–2946.
 - [31] A. Kendall and R. Cipolla, “Geometric loss functions for camera pose regression with deep learning,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 6555–6564.
 - [32] —, “Deep learning for camera relocalization: Models and approaches,” in *IEEE International Conference on Robotics and Automation (ICRA)*, 2016.
 - [33] A. Nassar, K. Amer, R. ElHakim, and M. ElHelw, “A deep cnn-based framework for enhanced aerial imagery registration with applications to uav geolocalization,” in *CVPR Workshops*, 2018.




INSTITUTO POLITÉCNICO NACIONAL
Unidad Profesional Interdisciplinaria de
Ingeniería Campus Tlaxcala



Sergio de Jesus Castillo Molano - Alumno de la carrera de *Ing. Inteligencia Artificial*
Unidad Profesional Interdisciplinaria de Ingeniería Campus Tlaxcala - Instituto Politécnico Nacional
Boleta: 2023710006, Tel: 771-266-9405, email: scastillom2200@alumno.ipn.mx

Firma: 

Miguel Alejandro Flores Sotelo - Alumno de la carrera de *Ing. Inteligencia Artificial*
Unidad Profesional Interdisciplinaria de Ingeniería Campus Tlaxcala - Instituto Politécnico Nacional
Boleta: 2023710010, Tel: 55-2520-8997, email: mfloress2200@alumno.ipn.mx

Firma: 

Gerardo Texis Texis
Asesor de Trabajo Terminal 1
Unidad Profesional Interdisciplinaria de Ingeniería Campus Tlaxcala - Instituto Politécnico Nacional
email: gtexist@ipn.mx

Firma: 

Alfredo Roldan Caballero
Asesor de Trabajo Terminal 1
Unidad Profesional Interdisciplinaria de Ingeniería Campus Tlaxcala - Instituto Politécnico Nacional
email: aroldanc@ipn.mx

Firma: 