



Instituto Politécnico Nacional
Unidad Profesional Interdisciplinaria de Ingeniería
Campus Tlaxcala



Reporte Técnico/Tesis


”Detección de objetos desde perspectiva
aérea mediante redes neuronales
convolucionales y técnicas de visión por
computadora”

No.TT2026-2_IA05

Presenta(n):

**Sergio de Jesus Castillo Molano, Ingeniería en Inteligencia
Artificial**

**Miguel Alejandro Flores Sotelo, Ingeniería en Inteligencia
Artificial**


Dr. Gerardo Taxis Taxis

Asesores:


Dr. Alfredo Roldan Caballero

Tlaxcala, Tlaxcala, a **5** de **JUNIO** de **2026**

”La Técnica al Servicio de la Patria”

Agradecimientos

Sergio de Jesús Castillo Molano

Primeramente, agradezco a Dios por darme la fortaleza, la salud, la sabiduría y la perseverancia necesarias para llegar hasta este momento. Su guía ha sido fundamental en cada etapa de mi vida, especialmente durante los momentos de dificultad, incertidumbre y esfuerzo que formaron parte de este camino académico y personal.

Agradezco al Instituto Politécnico Nacional y a la Unidad Profesional Interdisciplinaria de Ingeniería Campus Tlaxcala, por brindarme la oportunidad de formarme profesionalmente y por proporcionarme las herramientas necesarias para crecer tanto académica como personalmente. Ser parte de esta institución representa una responsabilidad y un orgullo, y concluir esta etapa dentro de ella es un logro que llevaré siempre con gratitud.

De manera especial, agradezco a mis asesores, el Dr. Gerardo Taxis Taxis y el Dr. Alfredo Roldán Caballero, por su orientación, paciencia y apoyo durante el desarrollo de este trabajo. Sus observaciones, conocimientos y recomendaciones fueron fundamentales para fortalecer el proyecto, mejorar su calidad y encaminarlo de forma adecuada hasta su conclusión.

A mi papá, Sergio Castillo Medina, le agradezco profundamente por enseñarme a estar preparado para enfrentar la vida, por inculcarme valores como la responsabilidad, la disciplina y el esfuerzo. Gracias por ser un ejemplo de trabajo y perseverancia, y por brindarme siempre tu apoyo y confianza para seguir adelante incluso en los momentos más difíciles.

A mi mamá, Janette Molano Mercado, le agradezco de todo corazón por enseñarme a enfrentar la vida incluso cuando uno no se siente completamente preparado. Gracias por tu cariño, tu fortaleza y tu apoyo incondicional durante cada etapa de mi vida. El haber salido de casa para estudiar como foráneo me hizo comprender aún más el valor de tu esfuerzo, tus consejos y todo lo que has hecho para ayudarme a cumplir mis metas.

A mi mejor amigo y hermano de vida, Miguel Alejandro Flores Sotelo, le agradezco sinceramente por su apoyo, compañía y amistad incondicional durante este proceso. Gracias por estar presente en los momentos difíciles, por brindarme palabras de ánimo cuando más las necesitaba y por formar parte importante de esta etapa de mi vida. Tu amistad ha sido una motivación para seguir adelante y recordar que este camino también se fortalece con las personas que nos acompañan de corazón.

A mis hermanos, Andrés de Jesús Castillo Molano y Yaritzi Janeth Castillo Molano, gracias por su compañía, apoyo y por estar presentes durante este proceso. Saber que cuento con ustedes ha sido una motivación importante para continuar

esforzándome y seguir creciendo personal y profesionalmente.

También agradezco a mi familia, amigos y compañeros, quienes de una u otra manera me brindaron apoyo, motivación y momentos de ánimo durante esta etapa. Cada consejo, conversación y muestra de apoyo contribuyó a hacer este camino más llevadero y significativo.

Finalmente, agradezco a todas las personas que contribuyeron directa o indirectamente en el desarrollo y conclusión de este trabajo terminal. Cada avance representó esfuerzo, aprendizaje y dedicación. Este logro no solo forma parte de una meta académica cumplida, sino también de una etapa de crecimiento personal que me impulsa a seguir adelante con compromiso, gratitud y determinación.

Miguel Alejandro Flores Sotelo

Al Instituto Politécnico Nacional y a la Unidad Profesional Interdisciplinaria de Ingeniería Campus Tlaxcala, les expreso mi más profundo agradecimiento por haberme formado no solo como profesional, sino como persona. A lo largo de esta etapa tuve la fortuna de contar con un cuerpo docente de una calidad excepcional, académicos comprometidos, con vastos conocimientos y, sobre todo, con la vocación genuina de enseñar, guiar y exigir lo mejor de cada estudiante. Todo lo aprendido no me pertenece solo a mí, sino también a quienes lo hicieron posible, y es mi responsabilidad devolverlo al mundo compartiéndolo con los demás, así como ellos lo hicieron conmigo.

De manera particular, agradezco a mis asesores el Dr. Gerardo Taxis Taxis y el Dr. Alfredo Roldán Caballero, quienes antes de ser guías de este trabajo terminal fueron profesores que dejaron huella en mi formación académica. Su orientación a lo largo del desarrollo de este proyecto y mi formación académica ha sido invaluable, con paciencia, claridad y un profundo dominio de su área, supieron conducir cada etapa con la precisión de quienes saben exactamente hacia dónde llevan a sus estudiantes.

A mi madre, Amalia Sotelo Velázquez, le debo más de lo que estas líneas pueden expresar. Desde el primer día creyó en mí incluso antes de que yo creyera en mí mismo. Su apoyo incondicional, su presencia constante y su capacidad de motivarme a perseguir mis metas han sido el motor silencioso detrás de cada logro. Eres la persona más valiosa en mi vida, y este trabajo lleva en cada página una parte de todo lo que me has dado.

A mi padre, Luis Miguel Flores Reyes Lira, le agradezco por enseñarme a soñar en grande. Su espíritu visionario, su ecuanimidad ante las circunstancias y su bondad como persona me han mostrado que se puede construir un camino propio sin perder el equilibrio. Gracias por inculcarme que los límites no son muros, sino líneas de partida.

A Sergio de Jesús Castillo Molano, compañero de carrera, coautor de este trabajo terminal y, con el tiempo, un hermano. Compartimos desde el primer semestre las mismas aulas, los mismos desvelos, las mismas victorias y los mismos tropiezos. Pocas veces en la vida uno encuentra a alguien con quien caminar tan a la par, y estoy profundamente agradecido de que este proyecto haya sido construido junto a una persona tan noble y comprometida como tú.

A mis compañeros de generación, gracias por hacer de esta etapa algo más que un proceso académico. Fuimos un equipo en el sentido más auténtico de la palabra,

nadie se quedó atrás porque ninguno lo permitió. Esa forma de entender el trabajo conjunto es algo que llevaré conmigo más allá de cualquier aula.

Finalmente, a todas las personas que de una u otra manera pusieron algo de sí en este camino: una palabra, un consejo, un momento de aliento. Este trabajo terminal es el resultado de un esfuerzo que no fue solo mío, y cada semestre superado fue la confirmación de algo en lo que creo profundamente, esforzarte por lo que quieres siempre trae consigo las mejores recompensas.

Resumen

El presente trabajo terminal aborda el desarrollo de un sistema integral de detección y seguimiento de objetos desde perspectiva aérea mediante técnicas de visión por computadora y aprendizaje profundo. La motivación principal surge de la dificultad de analizar manualmente imágenes y secuencias de video capturadas por vehículos aéreos no tripulados, especialmente en escenarios con objetos pequeños, alta densidad de instancias, oclusiones, variaciones de escala y fondos visualmente complejos. La contribución del proyecto no se limita a comparar arquitecturas de detección, sino que integra análisis de datos aéreos, entrenamiento bajo un marco experimental controlado, evaluación de precisión y eficiencia computacional, validación cruzada entre dominios y preparación para un pipeline con seguimiento multiobjeto, georreferenciación y despliegue en cómputo de borde.

Para el desarrollo del sistema se utiliza VisDrone-DET2019 como conjunto principal de entrenamiento y evaluación, ya que contiene imágenes reales capturadas desde drones con diez categorías de objetos. No obstante, se reconoce que el uso de un conjunto de datos específico puede introducir sesgos asociados con sus condiciones de captura, distribución de clases, tipos de escena y frecuencia de aparición de los objetos. Por esta razón, el trabajo incorpora un análisis exploratorio del desbalance de clases, tamaños de caja, densidad de objetos, oclusión y truncamiento. De manera complementaria, se considera UAVDT como conjunto de validación cruzada, debido a que comparte clases vehiculares con VisDrone y permite analizar la generalización ante un dominio aéreo distinto.

Como parte de la metodología, se realizó la organización del conjunto VisDrone, la conversión de anotaciones originales al formato YOLO normalizado, la verificación visual del preprocesamiento y el entrenamiento de YOLOv8n sobre VisDrone-DET2019. La configuración final utilizó imágenes de 1280 píxeles, batch de 4, optimizador AdamW, semilla de reproducibilidad igual a 0, precisión mixta FP16, *mosaic*=1.0, *mixup*=0.15 y *close_mosaic*=10. También se evaluó una configuración auxiliar con *mosaic*=0.5 para analizar si reducir la intensidad del mosaico mejoraba la detección de objetos pequeños; sin embargo, dicha configuración no superó el desempeño de *mosaic*=1.0, por lo que esta última se conserva como configuración principal.

Los resultados actuales muestran que VisDrone presenta un fuerte desbalance de clases, una alta proporción de objetos pequeños y escenas con elevada densidad de instancias. Con la configuración final, YOLOv8n alcanzó un mAP@0.5 de 0.4755, un mAP@0.5:0.95 de 0.2874, una precisión de 0.5944, un recall de 0.4641 y un F1-score de 0.5212. Además, el modelo cuenta con aproximadamente 3.01 millones de parámetros y 8.20 GFLOPs. En la medición preliminar de eficiencia sobre una GPU NVIDIA GeForce RTX 4050 Laptop, el modelo obtuvo una latencia promedio de 4.41 ms por imagen, equivalente a 226.58 FPS, con un consumo aproximado de 72.8

MB de VRAM y 1201.8 MB de RAM.

La clase *car* obtuvo el mejor desempeño, lo cual se relaciona con su alta representación dentro del conjunto de datos. En contraste, clases minoritarias y de menor tamaño visual, como *awning-tricycle*, *tricycle* y *bicycle*, presentaron mayores dificultades. Estos resultados confirman que el tamaño reducido de los objetos, la oclusión, la densidad de las escenas, el desbalance de clases y el posible sesgo de dominio influyen directamente en la capacidad de detección del modelo. Las etapas posteriores contemplan el entrenamiento y evaluación de RT-DETR bajo el mismo marco experimental, la validación cruzada completa sobre UAVDT, la integración de seguimiento multiobjeto mediante DeepSORT o ByteTrack y la evaluación de viabilidad en una plataforma NVIDIA Jetson Orin Nano con TensorRT FP16.

Términos/Palabras Clave

- Detección de objetos
- Visión por computadora
- Vehículos aéreos no tripulados
- YOLOv8n
- VisDrone
- Seguimiento multiobjeto
- Eficiencia computacional
- Edge AI

Índice General

1	Introducción	1
1.1	Antecedentes	2
1.2	Planteamiento del Problema	5
1.3	Objetivos	7
1.3.1	Objetivo General	7
1.3.2	Objetivos Específicos	7
1.4	Justificación	7
2	Marco Teórico	10
2.1	Visión por computadora y aprendizaje profundo	10
2.2	Detección de objetos mediante modelos de aprendizaje profundo	11
2.3	Detección de objetos desde perspectiva aérea	11
2.4	Preparación de datos y aumento de datos	12
2.5	Métricas de evaluación para detección de objetos	13
2.6	Seguimiento multiobjeto en secuencias de video	14
2.7	Eficiencia computacional, Edge AI y georreferenciación	15
2.8	Síntesis del marco teórico	15
3	Estado del Arte	17
4	Metodología	21
4.1	Diseño de investigación	21
4.2	Procedimiento general	21
4.3	Marco experimental controlado	22
4.4	Estado actual de avance metodológico	23
4.5	Preparación y análisis del conjunto VisDrone	24
4.6	Caracterización preliminar de UAVDT	24
4.7	Conversión y verificación de etiquetas	25
4.8	Configuración del entrenamiento de YOLOv8n	25
4.9	Evaluación del modelo YOLOv8n	26
4.10	Etapas pendientes de desarrollo	26
4.11	Consideraciones de reproducibilidad	27
5	Resultados	28
5.1	Resultados del análisis exploratorio de VisDrone	28
5.2	Densidad y dificultad de las escenas	30
5.3	Verificación del preprocesamiento	31
5.4	Entrenamiento de YOLOv8n	32
5.5	Desempeño por clase	35

5.6 Matriz de confusión	36
5.7 Eficiencia computacional preliminar	37
5.8 Caracterización preliminar de UAVDT	38
5.9 Síntesis de resultados actuales	38
5.10 Discusión final respecto al cronograma	39
5.11 Cronograma de Actividades	40
6 Conclusiones	41

Capítulo 1

Introducción

El uso de vehículos aéreos no tripulados, comúnmente conocidos como UAV o drones, ha adquirido una relevancia creciente en tareas de monitoreo, inspección, vigilancia, análisis de tráfico y búsqueda en zonas extensas o de difícil acceso. Estas plataformas permiten capturar imágenes y secuencias de video desde una perspectiva aérea, lo que facilita observar grandes superficies en menor tiempo y con menor intervención humana. Sin embargo, para que esta información visual sea útil en aplicaciones reales, no basta con capturar imágenes; es necesario procesarlas automáticamente para identificar objetos de interés, analizar su ubicación y, en el caso de video, mantener su seguimiento a lo largo del tiempo.

La visión por computadora y el aprendizaje profundo han permitido desarrollar modelos capaces de detectar objetos con altos niveles de precisión en imágenes convencionales. Dentro del estado del arte, arquitecturas como Faster R-CNN, SSD y YOLO han sido ampliamente utilizadas para tareas de detección, ya sea priorizando exactitud o eficiencia computacional [1, 2, 3]. Más recientemente, modelos como RT-DETR han incorporado mecanismos basados en Transformers para mejorar la detección en tiempo real, manteniendo una velocidad de inferencia competitiva [4]. No obstante, cuando estos modelos se aplican a imágenes capturadas desde UAV, el problema se vuelve más complejo debido a las condiciones propias de la perspectiva aérea.

Entre los principales retos de la detección aérea se encuentran la presencia de objetos pequeños, variaciones de escala por cambios de altitud, fondos heterogéneos, oclusiones parciales, cambios de iluminación y degradaciones producidas por el movimiento de la plataforma. Estos factores pueden afectar la capacidad de generalización de los modelos y aumentar la presencia de falsos positivos o falsos negativos [5, 6]. Además, en secuencias de video, la detección cuadro por cuadro puede generar inestabilidad temporal, pérdida de objetos o cambios de identidad, por lo que resulta necesario incorporar estrategias de seguimiento multiobjeto.

El presente trabajo terminal aborda el problema de la detección y seguimiento de objetos desde perspectiva aérea mediante el desarrollo de un sistema basado en técnicas de aprendizaje profundo y visión por computadora. Para ello, se utiliza el conjunto de datos VisDrone-DET2019 como base principal de entrenamiento y evaluación, ya que contiene imágenes reales capturadas desde drones con diez categorías de objetos, incluyendo peatones, personas, bicicletas, automóviles, camionetas, camiones, autobuses, motocicletas y otros vehículos ligeros [7]. De manera complementaria, se contempla el uso del conjunto UAVDT como validación cruzada, debido a que sus clases principales, automóvil, camión y autobús, coinciden parcial-

mente con las categorías presentes en VisDrone, permitiendo analizar la transferencia del modelo a un dominio aéreo distinto [8].

La propuesta técnica se plantea como un sistema integral y no únicamente como una comparación aislada de modelos. En primer lugar, se establece un marco experimental controlado para evaluar arquitecturas de detección con enfoques complementarios: YOLOv8n como modelo ligero y eficiente, y RT-DETR como arquitectura híbrida CNN-Transformer orientada a una mayor capacidad de representación en escenas complejas. En segundo lugar, se incorporan métricas de precisión y eficiencia computacional, como mAP@0.5 , mAP@0.5:0.95 , precisión, recall, F1-score, parámetros, GFLOPs, FPS, latencia, VRAM y RAM. Finalmente, el sistema considera la integración posterior de seguimiento temporal bajo el paradigma *tracking-by-detection*, utilizando algoritmos como DeepSORT o ByteTrack para mantener la identidad de los objetos entre cuadros consecutivos [9, 10].

Como parte del desarrollo actual del proyecto, ya se realizó la preparación del conjunto VisDrone, incluyendo la conversión de etiquetas al formato YOLO, la verificación visual de anotaciones y el análisis exploratorio de los datos. Este análisis permitió identificar características relevantes del problema, como el desbalance de clases, la alta presencia de objetos pequeños, la densidad elevada de instancias por imagen, la variación en las resoluciones, la oclusión y el truncamiento. A partir de estos hallazgos, se configuraron estrategias de aumento de datos como *mosaic*, *mixup*, variaciones HSV, escala, traslación y volteo horizontal. Estas técnicas incrementan la variabilidad visual y la densidad de entrenamiento, pero no corrigen por sí mismas el desbalance de clases; por ello, dicho desbalance se analiza explícitamente en los resultados por clase.

En los avances obtenidos hasta el momento, se completó el entrenamiento de YOLOv8n sobre VisDrone durante 100 épocas, utilizando imágenes de 1280 píxeles para conservar mayor información de los objetos pequeños. La configuración final empleó *mosaic*=1.0 y *close_mosaic*=10; adicionalmente, se realizó un experimento auxiliar con *mosaic*=0.5 para verificar si una menor intensidad de mosaico mejoraba la detección de objetos pequeños. La configuración principal obtuvo un mAP@0.5 de 0.4755, un mAP@0.5:0.95 de 0.2874, una precisión de 0.5944, un recall de 0.4641 y un F1-score de 0.5212. Se observó que la clase *car* obtuvo el mejor desempeño debido a su alta representación en el conjunto de datos, mientras que clases minoritarias como *awning-tricycle*, *tricycle* y *bicycle* presentaron mayores dificultades.

En síntesis, este reporte técnico documenta el desarrollo de un sistema de visión artificial para detección y seguimiento de objetos desde perspectiva aérea. La contribución principal consiste en integrar análisis de datos, entrenamiento reproducible, evaluación de precisión, medición de eficiencia computacional, validación cruzada y preparación para despliegue en cómputo de borde. Esta orientación permite responder no solo qué tan preciso es el detector, sino también qué tan viable resulta para un escenario UAV donde importan la latencia, el consumo de recursos y la consistencia temporal de las detecciones.

1.1 Antecedentes

La visión por computadora es un área de la inteligencia artificial que busca dotar a los sistemas computacionales de la capacidad de interpretar información visual proveniente de imágenes o secuencias de video. Sus aplicaciones abarcan tareas

como clasificación de imágenes, segmentación, reconocimiento de patrones, detección de objetos y seguimiento visual. En sus primeras etapas, muchos sistemas de visión artificial dependían de técnicas diseñadas manualmente, como la extracción de bordes, descriptores de textura, análisis de color o métodos basados en movimiento. Aunque estos enfoques permitieron resolver problemas específicos, su desempeño dependía en gran medida de las condiciones de captura y de la correcta selección de características por parte del investigador.

Con el desarrollo del aprendizaje profundo, la visión por computadora experimentó un avance importante. Las redes neuronales convolucionales, conocidas como CNN, permitieron aprender automáticamente características visuales a partir de los datos, reduciendo la dependencia de descriptores diseñados manualmente. A diferencia de los métodos tradicionales, las CNN pueden extraer información jerárquica de una imagen, comenzando con patrones simples como bordes y texturas, hasta representar estructuras más complejas asociadas con objetos completos. Esta capacidad convirtió a las redes convolucionales en una base fundamental para tareas modernas de detección y reconocimiento visual.

Dentro de la visión por computadora, la detección de objetos consiste en localizar e identificar instancias de diferentes clases dentro de una imagen. A diferencia de la clasificación, donde se asigna una etiqueta global a toda la imagen, la detección requiere determinar tanto la categoría del objeto como su ubicación mediante cajas delimitadoras. Este problema resulta especialmente importante en sistemas autónomos, videovigilancia, análisis de tráfico, robótica móvil y monitoreo mediante cámaras aéreas. Para evaluar el desempeño de estos sistemas, comúnmente se utilizan métricas como precisión, recall, intersección sobre unión e indicadores basados en mAP, los cuales permiten medir la calidad de las detecciones y su correspondencia con las anotaciones reales [1, 2, 3].

Históricamente, los detectores de objetos basados en aprendizaje profundo se han organizado en dos grandes enfoques: detectores de dos etapas y detectores de una etapa. Los detectores de dos etapas, como Faster R-CNN, primero generan regiones candidatas donde podría existir un objeto y después clasifican esas regiones. Este tipo de método suele ofrecer buena precisión, aunque con un mayor costo computacional [1]. Por otro lado, los detectores de una etapa, como SSD y YOLO, realizan la localización y clasificación de objetos en un solo proceso, lo que permite una inferencia más rápida [2, 3]. Esta diferencia es relevante para aplicaciones donde el tiempo de respuesta es importante, como en sistemas montados sobre drones o dispositivos de cómputo embebido.

En años recientes también han surgido arquitecturas híbridas que combinan redes convolucionales con mecanismos de atención basados en Transformers. Estos modelos buscan mejorar la representación global de la escena y atender relaciones espaciales más complejas entre objetos. Dentro de esta línea se encuentran arquitecturas como RT-DETR, que integran un *backbone* convolucional con módulos tipo Transformer para realizar detección en tiempo real [4]. Este tipo de evolución muestra que la detección de objetos continúa desarrollándose hacia modelos que equilibren precisión, velocidad y capacidad de generalización.

La detección de objetos desde perspectiva aérea representa un caso particular dentro de la visión por computadora. A diferencia de las imágenes capturadas desde cámaras terrestres, las imágenes obtenidas por UAV presentan condiciones visuales más variables. Los objetos suelen ocupar pocos píxeles dentro del encuadre debido a

la altura de vuelo, por lo que se consideran objetos pequeños. Además, la escala de los objetos cambia constantemente por la distancia entre la cámara y la escena, y los fondos suelen ser heterogéneos, con presencia de calles, edificios, vegetación, sombras o elementos visuales que pueden confundirse con los objetos de interés. También pueden aparecer oclusiones parciales, desenfoque por movimiento, vibraciones de la plataforma y variaciones de iluminación [5, 6].

Estos factores hacen que el dominio aéreo sea más complejo que otros escenarios de detección. Un modelo entrenado con imágenes convencionales puede no generalizar adecuadamente cuando se aplica a imágenes capturadas desde drones. Esta diferencia entre el dominio de entrenamiento y el dominio de prueba se conoce como *domain shift*. En el caso de la detección aérea, el cambio de dominio puede deberse a la altura de vuelo, el ángulo de la cámara, la resolución de las imágenes, la densidad de objetos, las condiciones ambientales y el tipo de sensor utilizado. Por esta razón, resulta necesario trabajar con conjuntos de datos específicos para UAV y evaluar los modelos bajo condiciones cercanas a escenarios reales [5, 6].

Entre los conjuntos de datos más utilizados para este tipo de problemas se encuentra VisDrone, el cual contiene imágenes y secuencias de video capturadas desde vehículos aéreos no tripulados. Este conjunto incluye diversas categorías de objetos, como peatones, personas, bicicletas, automóviles, camionetas, camiones, autobuses y motocicletas. Su importancia radica en que presenta condiciones visuales propias del dominio aéreo, tales como objetos pequeños, alta densidad de instancias, variaciones de escala y oclusiones [7]. Por ello, VisDrone se ha convertido en una referencia para entrenar y evaluar modelos de detección en imágenes capturadas desde drones.

Otro conjunto relevante es UAVDT, orientado principalmente a escenarios de tráfico capturados desde UAV. Este dataset contiene clases como automóvil, camión y autobús, las cuales coinciden parcialmente con las categorías presentes en VisDrone. Debido a esta relación entre clases, UAVDT puede utilizarse para evaluar la capacidad de generalización de un modelo entrenado en VisDrone hacia un dominio aéreo diferente [8]. Esta validación es importante porque permite analizar si el sistema aprende características útiles más allá del conjunto de entrenamiento o si su desempeño depende demasiado de las condiciones específicas de un solo dataset.

Además de la detección en imágenes individuales, el análisis de video requiere incorporar seguimiento temporal. La detección por cuadro independiente puede provocar inestabilidad, ya que un objeto puede ser detectado en un frame, perderse en el siguiente y volver a aparecer posteriormente. Para reducir este problema, se emplean estrategias de *tracking-by-detection*, donde primero se detectan los objetos en cada imagen y después se asocian las detecciones entre cuadros consecutivos. Este enfoque permite asignar identificadores de trayectoria, mantener la persistencia de identidad y reducir falsas alarmas en secuencias de video [11, 9, 10].

Algoritmos como SORT, DeepSORT y ByteTrack han sido utilizados como base para el seguimiento multiobjeto. SORT utiliza modelos de predicción de movimiento, como el filtro de Kalman, junto con técnicas de asociación para relacionar detecciones entre frames [11]. DeepSORT extiende esta idea incorporando características visuales profundas para mejorar la asociación de identidad [9]. ByteTrack, por su parte, aprovecha detecciones de alta y baja confianza para mejorar la continuidad de las trayectorias [10]. Estos métodos son relevantes en el contexto UAV porque permiten analizar no solo dónde aparece un objeto en una imagen, sino también cómo se mantiene a lo largo del tiempo.

Finalmente, en aplicaciones reales con drones, no solo es importante detectar objetos, sino también generar información útil para la toma de decisiones. Por ello, los sistemas de visión aérea pueden complementarse con registros estructurados que incluyan la clase detectada, la confianza del modelo, el identificador de trayectoria y la marca temporal. En algunos casos, también puede integrarse información de navegación del UAV, como GPS y orientación, para estimar la ubicación espacial de los eventos detectados [12, 13]. De esta forma, la detección y el seguimiento dejan de ser únicamente una tarea visual y se convierten en una herramienta de análisis para monitoreo, inspección y operación en entornos abiertos.

Con base en estos antecedentes, el presente trabajo se sitúa dentro del área de visión por computadora aplicada a plataformas UAV. El proyecto parte de los avances en redes neuronales convolucionales, detección de objetos, aprendizaje profundo y seguimiento multiobjeto, pero los enfoca en un escenario específico: la detección y seguimiento de objetos desde perspectiva aérea. Este contexto permite comprender la importancia de comparar arquitecturas como YOLOv8n y RT-DETR, utilizar conjuntos de datos especializados como VisDrone y UAVDT, y evaluar el sistema considerando tanto precisión como eficiencia computacional y consistencia temporal.

1.2 Planteamiento del Problema

El avance de la visión por computadora basada en aprendizaje profundo ha permitido desarrollar modelos capaces de detectar objetos con altos niveles de precisión en imágenes convencionales. Sin embargo, cuando estos modelos se aplican a imágenes y secuencias de video capturadas desde vehículos aéreos no tripulados, surgen condiciones visuales más complejas que afectan directamente su desempeño. A diferencia de una cámara terrestre fija o cercana al objeto, la perspectiva aérea modifica la escala, el ángulo de observación, la densidad de objetos y la apariencia visual de la escena, lo que dificulta la detección confiable de objetivos de interés.

El problema principal se relaciona con la detección y seguimiento de objetos desde perspectiva aérea en escenarios reales o similares a los encontrados durante vuelos de UAV. En este tipo de imágenes, los objetos suelen ocupar una región reducida del encuadre, por lo que contienen poca información visual para ser reconocidos por el modelo. Este fenómeno, conocido como detección de objetos pequeños, representa una de las principales limitaciones en el dominio aéreo, ya que puede provocar que el sistema confunda objetos con elementos del fondo o que no los detecte correctamente.

Además del tamaño reducido de los objetos, existen otros factores que incrementan la dificultad del problema. Las variaciones de altitud y distancia generan cambios constantes de escala; los fondos heterogéneos, como calles, edificios, vegetación o sombras, pueden generar falsas detecciones; y las condiciones de iluminación, oclusión parcial, movimiento de la plataforma y desenfoque afectan la calidad de las imágenes. En conjunto, estos factores reducen la capacidad de generalización de los modelos y pueden incrementar tanto los falsos positivos como los falsos negativos.

Otro aspecto relevante es la distribución de los datos utilizados para el entrenamiento. En conjuntos de datos aéreos como VisDrone, algunas clases aparecen con mucha mayor frecuencia que otras, lo que genera un desbalance de clases. Por ejemplo, categorías como automóviles suelen estar más representadas, mientras que otras clases, como bicicletas, autobuses o vehículos menos comunes, pueden tener

menor cantidad de ejemplos. Esta situación puede provocar que el modelo aprenda mejor las clases dominantes y tenga un desempeño más bajo en aquellas con menor representación.

También existe una dificultad asociada al cambio de dominio, conocido como *domain shift*. Un modelo entrenado en un conjunto de datos específico puede no comportarse de la misma forma cuando se evalúa en otro conjunto o en condiciones de vuelo diferentes. Por ello, no basta con medir el desempeño del sistema sobre el mismo conjunto utilizado durante el entrenamiento; también es necesario evaluar su capacidad de transferencia hacia otro dominio aéreo. En este trabajo, dicha problemática se considera mediante el uso de VisDrone como conjunto principal y UAVDT como conjunto de validación cruzada.

En secuencias de video, el problema no termina con detectar objetos de manera independiente en cada cuadro. La detección cuadro por cuadro puede generar inestabilidad temporal, ya que un objeto puede ser identificado en un instante, perderse en el siguiente y reaparecer posteriormente con otra detección. Esto dificulta mantener una trayectoria continua y afecta la utilidad del sistema en aplicaciones reales. Por esta razón, es necesario integrar un módulo de seguimiento temporal que permita asociar detecciones entre cuadros consecutivos, conservar identificadores de trayectoria y reducir falsas alarmas.

De esta manera, el problema de investigación se define como la necesidad de desarrollar y evaluar un sistema computacional capaz de detectar y seguir objetos desde perspectiva aérea, considerando las condiciones propias del dominio UAV: objetos pequeños, variación de escala, fondos complejos, oclusión, desbalance de clases, cambio de dominio y pérdida de consistencia temporal en video. El sistema debe ser evaluado mediante métricas estándar de detección, como $mAP@0.5$, $mAP@0.5:0.95$, precisión, recall e IoU, así como métricas de seguimiento multiobjeto como MOTA e IDF1.

El alcance de este trabajo se delimita al desarrollo de un pipeline de visión por computadora basado en aprendizaje profundo para detección y seguimiento de objetos en imágenes y videos aéreos. Se consideran como modelos principales YOLOv8n y RT-DETR, con el propósito de comparar el compromiso entre precisión y eficiencia computacional. El entrenamiento y evaluación principal se realiza sobre el conjunto VisDrone, mientras que UAVDT se utiliza para analizar la generalización del modelo en un dominio distinto. El trabajo no se enfoca en la construcción física del UAV ni en el diseño de nuevos sensores, sino en el procesamiento visual, entrenamiento, evaluación e integración del sistema de detección y seguimiento.

Por lo tanto, la investigación busca atender una problemática vigente dentro de la visión por computadora aplicada a UAV: lograr que los modelos de detección y seguimiento sean suficientemente precisos, consistentes y eficientes para operar en escenarios aéreos complejos. Resolver este problema resulta relevante tanto a nivel académico como práctico, ya que permite analizar las limitaciones de arquitecturas modernas en condiciones exigentes y aporta una base experimental para futuras aplicaciones en monitoreo, inspección, análisis de tráfico, vigilancia o búsqueda en espacios abiertos.

1.3 Objetivos

1.3.1 Objetivo General

Desarrollar y evaluar un sistema integral de detección y seguimiento de objetos desde perspectiva aérea mediante técnicas de visión por computadora y aprendizaje profundo, considerando precisión, eficiencia computacional, generalización entre dominios y viabilidad de despliegue en cómputo de borde.

1.3.2 Objetivos Específicos

1. Realizar un análisis exploratorio de los conjuntos de datos VisDrone y UAVDT, caracterizando la distribución de clases, el desbalance y la densidad de objetos por imagen, con el fin de identificar los retos específicos de cada conjunto para el entrenamiento y la evaluación.
2. Diseñar e implementar una estrategia de preprocesamiento y aumento de datos que incremente la variabilidad visual del conjunto de entrenamiento, mediante normalización de imágenes y etiquetas, transformaciones geométricas, ajustes fotométricos y técnicas de *augmentation* como *mosaic* y *mixup*, sin asumir que estas técnicas eliminan el desbalance de clases.
3. Implementar y entrenar arquitecturas de detección de objetos, YOLOv8n y RT-DETR, sobre el conjunto VisDrone bajo un marco experimental controlado, ajustando hiperparámetros y midiendo el desempeño mediante mAP@0.5, mAP@0.5:0.95, precisión, recall, F1-score e IoU.
4. Integrar un módulo de seguimiento temporal, *tracking-by-detection*, al pipeline de detección, cuantificando su contribución a la persistencia de identidad y a la reducción de falsas alarmas en secuencias de video mediante métricas multiobjeto como MOTA e IDF1.
5. Comparar el *trade-off* entre precisión y eficiencia computacional, considerando FPS, latencia, parámetros, GFLOPs, VRAM y RAM, y validar la generalización del modelo con mejor desempeño sobre el conjunto UAVDT, cuantificando su capacidad de transferencia a un dominio aéreo distinto al de entrenamiento.

1.4 Justificación

La detección y seguimiento automático de objetos desde plataformas aéreas representa una línea de investigación relevante dentro de la visión por computadora, debido a su aplicación en tareas de monitoreo, inspección, análisis de tráfico, vigilancia y búsqueda en zonas extensas o de difícil acceso. En estos escenarios, la revisión manual de imágenes y secuencias de video capturadas por UAV puede resultar lenta, demandante y propensa a errores humanos, especialmente cuando existe una gran cantidad de información visual por analizar. Por ello, el desarrollo de sistemas capaces de identificar objetos de interés de forma automática constituye una

alternativa útil para reducir la carga operativa y apoyar la toma de decisiones en contextos donde el tiempo de respuesta es un factor importante [14, 15].

Desde el punto de vista práctico, los resultados de esta investigación pueden aplicarse en sistemas de apoyo para el análisis de video aéreo, permitiendo detectar objetos de interés, mantener su seguimiento temporal y generar evidencia visual estructurada. Esto resulta útil en escenarios donde se requiere analizar grandes áreas desde una perspectiva elevada, como inspección de infraestructura, monitoreo urbano, búsqueda de personas u objetos y supervisión de zonas abiertas. Además, la posibilidad de registrar información asociada a cada evento, como clase detectada, nivel de confianza, identificador de trayectoria y ubicación estimada, permite que las detecciones tengan mayor utilidad operativa [12, 13].

En el ámbito académico y tecnológico, este trabajo se justifica porque aborda problemas que continúan siendo un reto en la visión por computadora aplicada a entornos aéreos. Entre estos retos se encuentran la detección de objetos pequeños, la variación de escala causada por cambios de altitud, la presencia de fondos complejos, las oclusiones parciales, el desbalance de clases, el cambio de dominio y las restricciones de cómputo en plataformas de Edge AI. Estas condiciones afectan la precisión y robustez de los modelos de aprendizaje profundo, por lo que resulta necesario evaluar su comportamiento en escenarios propios del dominio UAV [5, 6].

La originalidad del estudio radica en la integración de distintas etapas dentro de un mismo pipeline experimental: análisis de datos aéreos, preprocesamiento, aumento de datos, entrenamiento de modelos de detección, evaluación de métricas de precisión, medición de eficiencia computacional, comparación de arquitecturas, validación cruzada y seguimiento temporal. A diferencia de enfoques centrados únicamente en la detección por imagen individual, este trabajo considera también la consistencia temporal en secuencias de video mediante técnicas de *tracking-by-detection*. Asimismo, la comparación entre YOLOv8n y RT-DETR permite analizar el compromiso entre precisión y eficiencia computacional en un escenario complejo como la perspectiva aérea, sin presentar la contribución como una arquitectura nueva, sino como una integración experimental reproducible orientada a operación en UAV.

El alcance del proyecto también justifica la participación de dos integrantes, ya que el desarrollo requiere cubrir tareas complementarias. Por un lado, se atiende la preparación de datos, análisis exploratorio, conversión de etiquetas, configuración de entrenamiento y evaluación cuantitativa de modelos. Por otro lado, se considera la medición de eficiencia, comparación experimental, integración futura del seguimiento multiobjeto, validación cruzada y documentación reproducible del sistema. Esta división permite abordar el problema desde una perspectiva de ciencia de datos, aprendizaje profundo e ingeniería de sistemas, manteniendo trazabilidad entre código, resultados y reporte técnico.

Otro aspecto que aporta valor al proyecto es la validación cruzada entre conjuntos de datos. El entrenamiento principal se realiza sobre VisDrone, mientras que UAVDT se utiliza para evaluar la capacidad de generalización del modelo en un dominio aéreo diferente. Esta decisión permite analizar si el sistema conserva un desempeño aceptable fuera del conjunto utilizado durante el entrenamiento, lo cual es importante para estimar su posible comportamiento en escenarios reales con condiciones visuales distintas [7, 8].

Los beneficios potenciales de este trabajo son tanto directos como indirectos. De forma directa, se espera obtener un sistema funcional de detección y seguimiento

de objetos desde perspectiva aérea, evaluado mediante métricas estándar como mAP@0.5, mAP@0.5:0.95, precisión, recall, F1-score, IoU, MOTA e IDF1, además de métricas de eficiencia como FPS, latencia, parámetros, GFLOPs, VRAM y RAM. De forma indirecta, el proyecto puede servir como base para trabajos posteriores relacionados con sistemas UAV, visión artificial en tiempo real, Edge AI, georreferenciación de eventos y análisis automático de video aéreo. Además, los resultados permitirán identificar las fortalezas y limitaciones de las arquitecturas evaluadas bajo condiciones propias del dominio aéreo.

La viabilidad del estudio se sustenta en el uso de conjuntos de datos públicos y ampliamente utilizados en la literatura, como VisDrone y UAVDT, así como en la disponibilidad de herramientas de aprendizaje profundo y visión por computadora para entrenar, evaluar e integrar los modelos propuestos. La metodología planteada divide el desarrollo en fases claras: preparación y análisis de datos, entrenamiento de arquitecturas de detección, integración del seguimiento temporal, comparación de desempeño y validación de generalización. Esta organización permite que el proyecto sea factible dentro del tiempo y los recursos disponibles, además de facilitar una evaluación ordenada y reproducible.

En conjunto, la presente investigación se justifica por su relevancia práctica, su aporte académico, su originalidad metodológica y su factibilidad técnica. El desarrollo de un pipeline de detección y seguimiento desde perspectiva aérea permite atender una problemática vigente en visión por computadora, al mismo tiempo que proporciona evidencia experimental sobre el comportamiento de modelos modernos en escenarios complejos. Por ello, el proyecto representa una contribución útil para el análisis de imágenes UAV y para futuras aplicaciones en monitoreo, inspección y apoyo a la toma de decisiones en entornos abiertos, especialmente cuando se requiere equilibrar precisión, eficiencia y capacidad de operación en hardware limitado.

Capítulo 2

Marco Teórico

El marco teórico presenta los fundamentos técnicos que sustentan el desarrollo del sistema de detección y seguimiento de objetos desde perspectiva aérea. En lugar de abordar los conceptos de manera aislada, este capítulo los organiza en ejes temáticos: visión por computadora y aprendizaje profundo, detección de objetos, retos del dominio aéreo, preparación de datos, métricas de evaluación, seguimiento multiobjeto y eficiencia computacional para despliegue en plataformas embebidas.

2.1 Visión por computadora y aprendizaje profundo

La visión por computadora es un área de la inteligencia artificial orientada al análisis e interpretación automática de información visual proveniente de imágenes o secuencias de video. Su objetivo es extraer información útil de una escena, como la presencia de objetos, su ubicación, tamaño, movimiento o relación con otros elementos. Dentro de esta área se encuentran tareas como clasificación de imágenes, segmentación, detección de objetos y seguimiento visual.

Durante sus primeras etapas, muchos sistemas de visión por computadora dependían de características diseñadas manualmente, como bordes, texturas, color o descriptores geométricos. Sin embargo, estos métodos solían ser sensibles a cambios de iluminación, escala, perspectiva y condiciones de captura. Con el desarrollo del aprendizaje profundo, especialmente mediante redes neuronales convolucionales, fue posible aprender características visuales directamente a partir de los datos, reduciendo la dependencia de descriptores definidos manualmente.

Las redes neuronales convolucionales, conocidas como CNN, son modelos diseñados para procesar imágenes mediante filtros que recorren la imagen y extraen patrones visuales. En las primeras capas, una CNN aprende características simples como bordes, esquinas o texturas; en capas intermedias puede representar formas y partes de objetos; y en capas profundas aprende características más abstractas asociadas con objetos completos. Esta capacidad de extracción jerárquica convierte a las CNN en una base fundamental para tareas modernas de detección de objetos.

En el contexto de este trabajo, la visión por computadora y el aprendizaje profundo permiten construir un sistema capaz de analizar imágenes aéreas capturadas por UAV, localizar objetos de interés y clasificarlos en categorías específicas. Esto resulta especialmente importante porque las imágenes aéreas presentan condiciones más complejas que las imágenes convencionales, como objetos pequeños, alta densidad de instancias y cambios de escala.

2.2 Detección de objetos mediante modelos de aprendizaje profundo

La detección de objetos consiste en identificar qué objetos aparecen en una imagen y determinar dónde se encuentran. A diferencia de la clasificación de imágenes, donde se asigna una etiqueta global a toda la imagen, la detección requiere localizar cada instancia mediante una caja delimitadora o *bounding box*. Cada detección incluye, por tanto, dos elementos principales: la clase del objeto y su posición dentro de la imagen.

En modelos como YOLO, las cajas delimitadoras suelen representarse mediante el siguiente formato normalizado:

$$class_id, x_{center}, y_{center}, width, height \quad (2.1)$$

donde $class_id$ representa la clase del objeto, x_{center} y y_{center} indican el centro de la caja, y $width$ y $height$ representan su ancho y alto. Esta representación permite entrenar modelos de detección a partir de imágenes y etiquetas asociadas.

Los detectores de objetos basados en aprendizaje profundo suelen clasificarse en dos grandes enfoques: detectores de dos etapas y detectores de una etapa. Los detectores de dos etapas, como Faster R-CNN, primero generan regiones candidatas donde podría existir un objeto y después clasifican dichas regiones. Este tipo de método suele ofrecer buena precisión, aunque con mayor costo computacional [1]. Por otro lado, los detectores de una etapa, como SSD y YOLO, realizan la localización y clasificación en un solo proceso, lo que permite mayor velocidad de inferencia [2, 3].

En este proyecto se utiliza YOLOv8n como arquitectura ligera de detección. La letra n hace referencia a *nano*, lo que indica que se trata de una versión pequeña y eficiente. Esta característica resulta útil en escenarios donde se requiere baja latencia y menor consumo de recursos computacionales. YOLOv8n permite evaluar si un modelo ligero puede ofrecer un desempeño adecuado en imágenes aéreas, donde los objetos suelen ocupar pocos píxeles y aparecen en escenas densas.

Además, se considera RT-DETR como arquitectura complementaria. RT-DETR combina redes convolucionales con mecanismos de atención basados en Transformers, con el objetivo de mejorar la representación global de la escena y mantener una velocidad de inferencia competitiva [4]. En este trabajo, YOLOv8n representa un enfoque orientado a eficiencia, mientras que RT-DETR se considera una alternativa orientada a mayor capacidad de representación en escenas complejas.

2.3 Detección de objetos desde perspectiva aérea

La detección de objetos desde perspectiva aérea representa un caso particular dentro de la visión por computadora. A diferencia de las imágenes capturadas desde cámaras terrestres, las imágenes obtenidas por UAV presentan condiciones visuales más variables. Los objetos suelen ocupar una región pequeña dentro del encuadre, la escala cambia por la altura de vuelo, los fondos pueden ser heterogéneos y pueden aparecer oclusiones parciales, sombras, desenfoque por movimiento o vibraciones de la plataforma.

Uno de los retos principales en este dominio es la detección de objetos pequeños. Un objeto pequeño es aquel que ocupa pocos píxeles dentro de la imagen. En imá-

genes aéreas, esto ocurre con frecuencia porque la cámara cubre áreas amplias desde cierta altura. Como consecuencia, objetos como peatones, bicicletas o motocicletas pueden contener poca información visual, lo que dificulta su reconocimiento y localización precisa.

Otro reto importante es el cambio de dominio o *domain shift*. Un modelo entrenado en un conjunto de datos específico puede no generalizar correctamente cuando se evalúa en otro conjunto o en condiciones de vuelo distintas. En imágenes UAV, el cambio de dominio puede deberse a diferencias en altitud, ángulo de captura, resolución, iluminación, sensor, densidad de objetos o distribución de clases. Por esta razón, es necesario evaluar los modelos no solo en el conjunto principal de entrenamiento, sino también en un conjunto diferente que permita analizar su capacidad de generalización [5, 6].

En este trabajo se utiliza VisDrone-DET2019 como conjunto principal, ya que contiene imágenes reales capturadas desde drones con categorías como peatones, personas, bicicletas, automóviles, camionetas, camiones, triciclos, autobuses y motocicletas. Este conjunto es relevante porque presenta condiciones propias del dominio aéreo, como objetos pequeños, escenas densas, variaciones de escala y oclusiones [7]. De manera complementaria, se considera UAVDT como conjunto de validación cruzada, debido a que contiene clases vehiculares compartidas con VisDrone, como automóvil, camión y autobús [8].

2.4 Preparación de datos y aumento de datos

La calidad de los datos es un factor determinante en el desempeño de un modelo de detección. Antes del entrenamiento, es necesario preparar las imágenes y etiquetas para que sean compatibles con la arquitectura seleccionada. En este proyecto, las anotaciones originales de VisDrone se convierten al formato YOLO normalizado, lo que permite entrenar modelos de la familia YOLO y mantener una correspondencia directa entre imágenes y cajas delimitadoras.

El preprocesamiento también incluye la revisión visual de las etiquetas, la organización del conjunto en particiones de entrenamiento, validación y prueba, y la verificación de que las clases estén correctamente asignadas. Esta etapa es importante porque errores en las anotaciones, cajas desplazadas o clases mal asociadas pueden provocar que el modelo aprenda patrones incorrectos.

Otro aspecto relevante es el desbalance de clases. Este ocurre cuando algunas categorías tienen muchos ejemplos y otras tienen pocos. En conjuntos aéreos como VisDrone, clases como *car* suelen aparecer con mayor frecuencia, mientras que clases como *awning-tricycle*, *tricycle* o *bus* pueden tener menor representación. Este desbalance puede afectar el entrenamiento, ya que el modelo tiende a aprender mejor las clases dominantes y puede presentar menor desempeño en clases minoritarias.

Para mejorar la generalización se utilizan técnicas de aumento de datos o *data augmentation*. Estas técnicas generan variaciones de las imágenes originales mediante transformaciones geométricas y fotométricas, como escalado, recorte, desplazamiento, volteo horizontal, cambios de brillo, saturación y color. También existen técnicas más avanzadas como *mosaic* y *mixup*, que permiten incrementar la diversidad visual del conjunto de entrenamiento y simular condiciones más variadas.

En el contexto de imágenes aéreas, el aumento de datos resulta especialmente útil porque puede simular cambios de escala, variaciones de iluminación y escenas

con alta densidad de objetos. Sin embargo, estas técnicas no eliminan por completo el sesgo del conjunto de datos ni modifican de manera directa la frecuencia real de clases minoritarias. Por ello, el desbalance debe analizarse mediante la distribución de clases y el desempeño por categoría, en lugar de asumirse como resuelto durante el entrenamiento.

2.5 Métricas de evaluación para detección de objetos

La evaluación de un detector requiere medir tanto la calidad de la clasificación como la precisión en la localización de las cajas delimitadoras. Una métrica fundamental es la intersección sobre unión, o IoU, que mide el grado de coincidencia entre la caja predicha por el modelo y la caja real anotada:

$$IoU = \frac{\text{Area de interseccion}}{\text{Area de union}} \quad (2.2)$$

A partir de la comparación entre predicciones y anotaciones reales se definen los verdaderos positivos, falsos positivos y falsos negativos. La precisión indica qué proporción de las detecciones realizadas por el modelo fueron correctas:

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2.3)$$

El recall mide qué proporción de los objetos reales fueron detectados correctamente:

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2.4)$$

Estas dos métricas permiten analizar comportamientos distintos. Una precisión alta indica que el modelo comete pocos falsos positivos, mientras que un recall alto indica que detecta una mayor proporción de los objetos presentes. En imágenes aéreas, lograr un equilibrio entre ambas métricas puede ser difícil debido a la presencia de objetos pequeños, oclusiones y fondos complejos.

El F1-score resume el equilibrio entre precisión y recall mediante una media armónica:

$$F1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (2.5)$$

Esta métrica es útil cuando existe desbalance de clases o cuando se desea analizar de forma conjunta la capacidad del modelo para evitar falsos positivos y reducir falsos negativos.

El mAP, o *mean Average Precision*, resume el desempeño general del detector a partir de las curvas precisión-recall. En este trabajo se consideran dos variantes: mAP@0.5 y mAP@0.5:0.95. La primera utiliza un umbral de IoU de 0.5, mientras que la segunda evalúa varios umbrales entre 0.5 y 0.95, por lo que es más estricta. Esta diferencia permite distinguir entre modelos que detectan objetos de forma aproximada y modelos que localizan cajas con mayor precisión.

Además de las métricas de precisión, se consideran métricas de complejidad y eficiencia. Los parámetros del modelo indican el número de pesos aprendibles, mientras que los GFLOPs aproximan el costo computacional teórico de una inferencia. La latencia, los FPS, la VRAM y la RAM dependen del hardware utilizado, por lo que deben reportarse junto con el equipo donde fueron medidos.

Tabla 1: Métricas consideradas para evaluar precisión y eficiencia del sistema.

Tipo	Métrica		Propósito
Precisión	mAP@0.5 mAP@0.5:0.95	y	Evaluar la calidad global de detección y localización bajo distintos umbrales de IoU.
Precisión	Precisión, recall F1-score	y	Analizar falsos positivos, falsos negativos y equilibrio entre ambos.
Complejidad	Parámetros GFLOPs	y	Estimar tamaño del modelo y costo computacional teórico.
Eficiencia	Latencia y FPS		Medir tiempo de respuesta y velocidad de inferencia en un hardware específico.
Recursos	VRAM y RAM		Cuantificar el consumo de memoria durante la inferencia.

2.6 Seguimiento multiobjeto en secuencias de video

Aunque la detección de objetos en imágenes individuales es una etapa fundamental, muchas aplicaciones con UAV requieren analizar secuencias de video. En este caso, no basta con detectar objetos en cada cuadro de forma independiente; también es necesario mantener la identidad de cada objeto a lo largo del tiempo. Este proceso se conoce como seguimiento multiobjeto.

En este proyecto se considera el enfoque *tracking-by-detection*. Primero, el detector identifica los objetos presentes en cada cuadro del video; después, un algoritmo de seguimiento asocia las detecciones entre cuadros consecutivos para construir trayectorias. Este enfoque permite asignar identificadores a los objetos, conservar la continuidad temporal y reducir inestabilidades producidas por detecciones perdidas o cambios de identidad.

Entre los métodos más utilizados se encuentran SORT, DeepSORT y ByteTrack. SORT combina predicción de movimiento, comúnmente mediante filtro de Kalman, con asociación de detecciones entre cuadros [11]. DeepSORT extiende este enfoque incorporando características visuales profundas para mejorar la asociación de identidad [9]. ByteTrack aprovecha detecciones de alta y baja confianza para mantener trayectorias más estables en escenarios donde algunos objetos pueden ser detectados con baja seguridad [10].

Para evaluar el seguimiento multiobjeto se utilizan métricas como MOTA e IDF1. MOTA mide el desempeño general del seguimiento considerando falsos positivos, falsos negativos y cambios de identidad:

$$MOTA = 1 - \frac{FN + FP + IDSW}{GT} \quad (2.6)$$

IDF1 mide qué tan bien se conserva la identidad de los objetos durante la secuencia:

$$IDF1 = \frac{2IDTP}{2IDTP + IDFP + IDFN} \quad (2.7)$$

Estas métricas son importantes porque un sistema de visión aérea no solo debe detectar objetos en imágenes aisladas, sino también mantener trayectorias consistentes en video.

2.7 Eficiencia computacional, Edge AI y georreferenciación

En aplicaciones con UAV, la precisión del modelo no es el único criterio relevante. También es necesario considerar la eficiencia computacional, ya que el procesamiento puede realizarse en dispositivos con recursos limitados. Dos métricas comunes para evaluar la eficiencia son FPS y latencia. Los FPS indican cuántas imágenes procesa el sistema por segundo, mientras que la latencia indica el tiempo necesario para generar una predicción. A diferencia de mAP, precisión, recall o F1-score, estas métricas dependen directamente del hardware, del tamaño de entrada, del formato de inferencia y del tamaño de lote utilizado.

El concepto de Edge AI se refiere al uso de modelos de inteligencia artificial directamente en dispositivos cercanos a la fuente de datos, sin depender completamente de servidores externos. En el caso de un UAV, esto permitiría procesar imágenes durante el vuelo, reducir tiempos de respuesta y operar en escenarios donde la conectividad puede ser limitada. Sin embargo, también exige modelos eficientes, bajo consumo de memoria y optimización para hardware específico.

En este trabajo se contempla el despliegue futuro en una plataforma NVIDIA Jetson Orin Nano, utilizando TensorRT FP16 para acelerar la inferencia. Esta etapa permitirá evaluar si el sistema puede operar bajo restricciones cercanas a una aplicación real. Por ello, la comparación entre YOLOv8n y RT-DETR no debe considerar únicamente métricas de precisión, sino también velocidad, latencia, consumo de memoria y costo computacional. Las mediciones realizadas en una GPU de entrenamiento o en una GPU de laptop se reportan como referencia experimental, pero no sustituyen la evaluación final en el hardware objetivo.

Finalmente, la detección y el seguimiento pueden complementarse con georreferenciación de eventos. Esto consiste en asociar cada detección con información espacial, como coordenadas GPS, altura, orientación del UAV y parámetros de cámara. De esta forma, cada evento detectado puede registrarse con clase, confianza, identificador de trayectoria, marca temporal y ubicación aproximada [13]. Esta integración convierte al sistema en una herramienta más útil para monitoreo, inspección, análisis de tráfico o búsqueda en espacios abiertos.

2.8 Síntesis del marco teórico

Los conceptos presentados en este capítulo establecen la base técnica del proyecto. La visión por computadora y el aprendizaje profundo permiten analizar imágenes aéreas y extraer información visual relevante. Los detectores de objetos, como

YOLOv8n y RT-DETR, proporcionan mecanismos para localizar y clasificar objetos en escenas complejas. A su vez, los conjuntos VisDrone y UAVDT permiten entrenar y evaluar modelos bajo condiciones propias del dominio UAV.

También se identificaron los principales retos del problema: objetos pequeños, desbalance de clases, alta densidad de instancias, oclusiones, variaciones de escala y cambio de dominio. Las métricas de detección y seguimiento permiten evaluar el desempeño del sistema, mientras que la eficiencia computacional y el enfoque Edge AI son necesarios para aproximar el proyecto a una aplicación real en plataformas UAV. Con estos fundamentos, se establece la base conceptual para la metodología y los resultados presentados en los capítulos siguientes.

Capítulo 3

Estado del Arte

La detección y seguimiento de objetos desde perspectiva aérea ha sido abordada desde diferentes enfoques dentro de la visión por computadora. La literatura revisada coincide en que el dominio UAV presenta retos particulares frente a las imágenes convencionales, principalmente por la presencia de objetos pequeños, variaciones de escala, fondos complejos, oclusiones, cambios de iluminación, desenfoque por movimiento y diferencias entre los datos de entrenamiento y los escenarios reales de evaluación [5, 6].

Los conjuntos de datos especializados han sido fundamentales para evaluar este tipo de sistemas. VisDrone-DET2019 se ha consolidado como una referencia para la detección de objetos en imágenes capturadas desde drones, ya que contiene escenas densas, objetos pequeños y diferentes categorías de peatones y vehículos [7]. De manera complementaria, UAVDT permite evaluar detección y seguimiento en videos aéreos, principalmente en escenarios de tráfico, por lo que resulta útil para analizar la generalización de los modelos en un dominio UAV distinto [8].

En cuanto a los modelos de detección, los enfoques basados en aprendizaje profundo han utilizado arquitecturas como Faster R-CNN, SSD y YOLO. Faster R-CNN se caracteriza por su esquema de dos etapas y por ofrecer buena precisión, aunque con mayor costo computacional [1]. Por otro lado, SSD y YOLO realizan la detección en una sola etapa, lo que permite una inferencia más rápida y favorece su uso en aplicaciones donde el tiempo de respuesta es importante [2, 3]. Más recientemente, RT-DETR ha integrado mecanismos basados en Transformers para mejorar la detección en tiempo real, ofreciendo una alternativa competitiva frente a detectores tradicionales basados en CNN [4].

En secuencias de video, la detección por cuadro individual puede generar pérdida de objetos, falsas alarmas o cambios de identidad entre cuadros consecutivos. Por ello, se han utilizado métodos de seguimiento multiobjeto bajo el enfoque *tracking-by-detection*. SORT utiliza predicción de movimiento y asociación de detecciones, DeepSORT incorpora características visuales profundas para mejorar la identidad, y ByteTrack aprovecha detecciones de alta y baja confianza para mantener trayectorias más estables [11, 9, 10].

También existen trabajos que integran la detección con información espacial o con aplicaciones específicas. Božić-Štulić et al. proponen un modelo para detección y localización automática en imágenes aéreas usando CNN [12]. Sambolek e Ivašić-Kos abordan la detección de personas y estimación de geolocalización en imágenes UAV [13]. En aplicaciones de búsqueda y rescate, Ramírez-Ayala et al. trabajan con detección de personas desde perspectiva aérea usando imágenes térmicas [15],

mientras que Ciccone y Ceruti estudian la detección de objetos pequeños con YOLO en escenarios de rescate con drones [14].

La Tabla 2 presenta una comparación de los trabajos revisados, considerando su descripción general, ventajas, limitantes y relación con la propuesta desarrollada en este trabajo terminal.

Tabla 2: Comparación de trabajos relacionados con la detección y seguimiento de objetos desde perspectiva aérea.

Trabajo	Descripción	Ventajas	Limitantes	Relación con esta propuesta
Tang et al. [5]	Revisión sobre detección de objetos en UAV con aprendizaje profundo.	Identifica retos del dominio UAV, como objetos pequeños, variación de escala y fondos complejos.	No propone un sistema experimental propio.	Sirve como base para justificar los retos abordados.
Hua et al. [6]	Revisión sobre detección de objetos pequeños en imágenes aéreas.	Profundiza en el problema de <i>small objects</i> .	No se enfoca directamente en seguimiento temporal.	Apoya la necesidad de evaluar objetos pequeños.
Du et al. [7]	Presentan VisDrone-DET2019 como benchmark para detección en imágenes de drones.	Contiene escenas reales, densas, con oclusiones y múltiples categorías.	Presenta desbalance de clases y alta dificultad.	Es el conjunto principal de entrenamiento y evaluación.
Du et al. [8]	Proponen UAVDT como benchmark para detección y seguimiento en video UAV.	Permite evaluar modelos en secuencias aéreas de tráfico.	Tiene menos clases que VisDrone.	Se utiliza para validar la generalización del modelo.
Ren et al. [1]	Proponen Faster R-CNN como detector de dos etapas.	Ofrece buena precisión mediante regiones candidatas.	Su costo computacional es mayor.	Sirve como referencia para contrastar precisión y eficiencia.
Liu et al. [2]	Proponen SSD como detector de una etapa.	Permite detección rápida en una sola pasada.	Puede fallar en objetos pequeños o escenas complejas.	Representa una línea de detectores eficientes similar a YOLO.

Trabajo	Descripción	Ventajas	Limitantes	Relación con esta propuesta
Redmon et al. [3]	Proponen YOLO como detector de objetos en tiempo real.	Tiene alta velocidad de inferencia.	Puede perder precisión en objetos pequeños o escenas densas.	Fundamenta el uso de YOLOv8n como modelo ligero.
Zhao et al. [4]	Presentan RT-DETR como detector en tiempo real basado en CNN y Transformers.	Busca mejorar precisión manteniendo velocidad competitiva.	Puede requerir más recursos computacionales.	Se compara contra YOLOv8n para analizar precisión y eficiencia.
Bewley et al. [11]	Proponen SORT para seguimiento multiobjeto.	Es simple, rápido y útil para asociar detecciones entre cuadros.	Depende de la calidad del detector.	Sirve como base del enfoque <i>tracking-by-detection</i> .
Wojke et al. [9]	Extienden SORT mediante DeepSORT, agregando descriptores visuales.	Mejora la asociación de identidad en video.	Puede aumentar el costo computacional.	Es una alternativa para mantener identidades en secuencias UAV.
Zhang et al. [10]	Proponen ByteTrack para seguimiento multiobjeto.	Aprovecha detecciones de alta y baja confianza.	Depende del detector base.	Puede reducir pérdida de identidad y falsas alarmas.
Božić-Štulić et al. [12]	Integran detección y localización automática en imágenes aéreas usando CNN.	Relaciona detección visual con información espacial.	Depende de condiciones específicas de captura.	Apoya la generación de eventos útiles a partir de detecciones.
Sambolek e Ivašić-Kos [13]	Trabajan detección de personas y estimación de geolocalización en imágenes UAV.	Convierte detecciones en información con ubicación aproximada.	Se centra principalmente en personas.	Refuerza el registro de eventos con información espacial.
Ramírez-Ayala et al. [15]	Detectan personas en zonas boscosas usando imágenes térmicas aéreas.	Es útil para búsqueda y rescate.	Se enfoca en imágenes térmicas y una sola clase.	Muestra la utilidad práctica de la detección aérea.

Trabajo	Descripción	Ventajas	Limitantes	Relación con esta propuesta
Ciccone y Ceruti [14]	Analizan detección de objetos pequeños con YOLO para rescate con drones.	Enfatiza detección en tiempo real y objetos pequeños.	Está orientado a una aplicación específica.	Refuerza la pertinencia de evaluar YOLO en escenarios UAV.
Este trabajo	Propone un sistema integral con YOLOv8n, RT-DETR, VisDrone, UAVDT, tracking y preparación para despliegue en borde.	Integra EDA, preprocesamiento, entrenamiento, F1, eficiencia, validación cruzada y seguimiento temporal.	Puede afectarse por desbalance, objetos pequeños, oclusión y cambio de dominio.	Evalúa precisión, eficiencia, generalización y consistencia temporal en perspectiva aérea.

Como se observa en la Tabla 2, los trabajos revisados abordan componentes importantes del problema, como detección, seguimiento, datasets UAV, geolocalización o aplicaciones específicas. Sin embargo, varios de ellos se concentran en una sola etapa del proceso. En contraste, el presente trabajo propone integrar detección, seguimiento temporal, comparación de arquitecturas, validación cruzada entre conjuntos de datos y medición de eficiencia dentro de un mismo pipeline experimental.

La brecha principal identificada es que la detección desde perspectiva aérea no puede resolverse únicamente como un problema de detección convencional ni como una comparación aislada de modelos. Las condiciones propias del dominio UAV requieren considerar objetos pequeños, escenas densas, variaciones de escala, desbalance de clases, eficiencia computacional, generalización entre dominios y estabilidad temporal. Por ello, este trabajo plantea una evaluación controlada de YOLOv8n, como arquitectura ligera orientada a eficiencia, y RT-DETR, como arquitectura con mayor capacidad de representación, además de considerar seguimiento multiobjeto para mejorar la consistencia en secuencias de video.

En síntesis, el estado del arte muestra que una solución robusta para detección y seguimiento desde UAV debe equilibrar cuatro elementos principales: precisión en la detección, eficiencia computacional, capacidad de generalización y consistencia temporal. Estos elementos sustentan la propuesta de este trabajo terminal y orientan la metodología de evaluación planteada.

Capítulo 4

Metodología

La metodología de este trabajo describe el procedimiento aplicado para desarrollar el sistema de detección de objetos desde perspectiva aérea hasta la fase actual del proyecto. A diferencia de una propuesta general, este capítulo documenta las etapas ya realizadas: organización y análisis de los datos, conversión de anotaciones, verificación del preprocesamiento y entrenamiento inicial de YOLOv8n sobre VisDrone-DET2019. También se señalan las etapas que continúan pendientes, correspondientes al entrenamiento de RT-DETR, la integración del seguimiento multiobjeto, la validación cruzada completa sobre UAVDT y el despliegue en Jetson Orin Nano.

4.1 Diseño de investigación

El trabajo corresponde a un estudio aplicado, experimental y cuantitativo. Es aplicado porque busca construir una solución computacional para detectar y posteriormente seguir objetos en imágenes y videos capturados desde perspectiva aérea. Es experimental porque se entrenan modelos de detección bajo configuraciones controladas y se evalúa su desempeño mediante métricas objetivas. Es cuantitativo porque los resultados se analizan mediante indicadores numéricos como mAP@0.5, mAP@0.5:0.95, precisión, recall, F1-score, parámetros, GFLOPs, FPS, latencia, VRAM y RAM.

Hasta la fase actual, el desarrollo experimental se ha concentrado en el análisis del conjunto VisDrone-DET2019, la preparación de etiquetas en formato YOLO y el entrenamiento de YOLOv8n. Esta primera arquitectura permite establecer una línea base de desempeño para el problema de detección aérea. La comparación con RT-DETR y la integración del seguimiento temporal se mantienen como fases posteriores del proyecto.

4.2 Procedimiento general

El procedimiento metodológico del proyecto se organizó en cinco fases principales. Sin embargo, de acuerdo con el avance actual del cronograma, no todas las fases se encuentran en el mismo estado de desarrollo. Hasta esta etapa se completó la preparación y análisis de los datos, se realizó la conversión y verificación de etiquetas, y se entrenó el primer modelo de detección, YOLOv8n, sobre VisDrone-DET2019. Por tanto, el proyecto se encuentra actualmente en la fase de

entrenamiento y evaluación de modelos, con YOLOv8n completado y RT-DETR pendiente de entrenamiento.

La Figura 1 muestra el flujo metodológico general del sistema, indicando el estado actual de cada fase. Esta representación permite diferenciar las actividades ya realizadas de aquellas que continúan como trabajo posterior dentro del desarrollo del trabajo terminal.




Figura 1: Flujo metodológico del proyecto y estado actual de avance.

4.3 Marco experimental controlado

Para responder a la necesidad de una evaluación justa, los modelos se plantean bajo un marco experimental controlado. Esto significa que la comparación entre arquitecturas debe realizarse manteniendo constantes las particiones del conjunto de datos, la resolución objetivo, el formato de anotación, la semilla de reproducibilidad, las clases evaluadas y las métricas utilizadas. De esta forma, las diferencias observadas pueden atribuirse principalmente al comportamiento de cada arquitectura y no a cambios arbitrarios en el protocolo de entrenamiento o evaluación.

Tabla 3: Criterios del marco experimental controlado.

Criterio	Aplicación en el proyecto
Dataset principal	VisDrone-DET2019 con las mismas particiones de entrenamiento, validación y prueba definidas en <code>configs/visdrone.yaml</code> .
Formato de etiquetas	Conversión de anotaciones originales de VisDrone al formato YOLO normalizado.
Resolución objetivo	1280 píxeles, seleccionada por la alta proporción de objetos pequeños identificada en el EDA.
Semilla de reproducibilidad	<code>seed=0</code> en los scripts de entrenamiento para reducir variación entre corridas.
Métricas de precisión	mAP@0.5, mAP@0.5:0.95, precisión, recall, F1-score e IoU.
Métricas de eficiencia	Parámetros, GFLOPs, latencia, FPS, VRAM y RAM, reportadas junto con el hardware usado.
Validación cruzada	UAVDT como dominio aéreo distinto con clases vehiculares parcialmente compartidas.

4.4 Estado actual de avance metodológico

La Tabla 4 resume el estado de avance de las etapas consideradas en la metodología. Esta organización permite distinguir entre las actividades ya ejecutadas y aquellas que continúan pendientes dentro del cronograma del trabajo terminal.

Tabla 4: Estado actual de avance metodológico del proyecto.

Etapa	Estado	Evidencia generada
Análisis exploratorio de VisDrone	Completado	Tablas y gráficas de distribución de clases, tamaño de objetos, densidad, resoluciones, truncamiento y oclusión.
Análisis preliminar de UAVDT	Completado	Distribución de clases y comparación preliminar con VisDrone.
Conversión de etiquetas VisDrone a YOLO	Completado	Script de conversión y etiquetas normalizadas.
Verificación visual de etiquetas	Completado	Imágenes con cajas delimitadoras superpuestas sobre objetos reales.
Entrenamiento de YOLOv8n	Completado	Pesos del modelo, curvas de entrenamiento, métricas globales, F1-score, parámetros, GFLOPs, matriz de confusión y predicciones de validación.
Entrenamiento de RT-DETR	Pendiente	Se realizará para comparar precisión y eficiencia contra YOLOv8n.
Seguimiento multiobjeto	Pendiente	Se integrarán métodos como DeepSORT o ByteTrack.
Despliegue en Jetson Orin Nano	Pendiente	Se evaluará la inferencia optimizada con TensorRT FP16.

4.5 Preparación y análisis del conjunto VisDrone

La primera etapa consistió en organizar y analizar el conjunto VisDrone-DET2019, utilizado como base principal de entrenamiento y evaluación. Este conjunto contiene imágenes capturadas desde vehículos aéreos no tripulados y diez categorías de objetos: *pedestrian*, *people*, *bicycle*, *car*, *van*, *truck*, *tricycle*, *awning-tricycle*, *bus* y *motor* [7].

El análisis exploratorio se realizó en el notebook `01_eda_visdrone.ipynb`. A partir de las anotaciones del conjunto de entrenamiento se construyeron tablas y gráficas para estudiar la distribución de clases, el tamaño de las cajas delimitadoras, la densidad de objetos por imagen, la variación de resoluciones, la presencia de truncamiento y la oclusión. Este análisis permitió identificar los principales retos del conjunto antes del entrenamiento.

Como resultado, se contabilizaron 343,171 detecciones válidas en entrenamiento. Se observó un desbalance importante entre clases, donde *car* concentró 144,865 detecciones, equivalente al 42.21% del total. También se identificó que el 60.47% de las instancias corresponde a objetos pequeños bajo el criterio COCO. Estos hallazgos fueron utilizados para justificar el uso de una resolución de entrada alta durante el entrenamiento y técnicas de aumento de datos orientadas a mejorar la robustez del modelo.

4.6 Caracterización preliminar de UAVDT

Además de VisDrone, se realizó un análisis preliminar de UAVDT mediante el notebook `02_eda_uavdt.ipynb`. Este conjunto se considera para la validación

cruzada posterior, ya que contiene clases vehiculares compartidas con VisDrone: *car*, *truck* y *bus* [8].

El análisis permitió caracterizar la distribución de clases y comparar de forma inicial ambos conjuntos. UAVDT presentó 35,007 detecciones en entrenamiento, con un desbalance mayor que VisDrone. La clase *car* representó el 96.25% de las detecciones, mientras que *bus* y *truck* representaron el 2.94% y 0.81%, respectivamente. Esta caracterización confirma que UAVDT puede utilizarse para estudiar cambio de dominio, aunque sus resultados deberán interpretarse considerando su fuerte desbalance interno.

4.7 Conversión y verificación de etiquetas

Las anotaciones originales de VisDrone se encuentran en un formato propio basado en coordenadas absolutas, con la estructura:

$$\begin{aligned} & \textit{bbox_left}, \textit{bbox_top}, \textit{bbox_width}, \textit{bbox_height}, \\ & \textit{score}, \textit{category}, \textit{truncation}, \textit{occlusion} \end{aligned} \quad (4.1)$$

Para entrenar YOLOv8n fue necesario convertir estas etiquetas al formato YOLO normalizado:

$$\textit{class_id}, \textit{x_center}, \textit{y_center}, \textit{width}, \textit{height} \quad (4.2)$$

La conversión se implementó mediante el script `src/preprocessing/convert_visdrone_to_yolo.py`. El procedimiento transformó las coordenadas absolutas de cada caja delimitadora en coordenadas normalizadas respecto al ancho y alto de cada imagen. También se ajustaron los índices de clase para que coincidieran con el orden definido en el archivo de configuración `configs/visdrone.yaml`.

Posteriormente, se realizó una verificación visual en el notebook de preprocesamiento. En esta etapa se superpusieron las cajas convertidas sobre imágenes reales del conjunto para comprobar que las anotaciones coincidieran correctamente con los objetos. Esta revisión fue necesaria para evitar errores de entrenamiento causados por cajas desplazadas, escaladas incorrectamente o asociadas a clases equivocadas.

4.8 Configuración del entrenamiento de YOLOv8n

Una vez preparado el conjunto de datos, se entrenó YOLOv8n sobre VisDrone-DET2019 mediante el script `src/training/train_yolov8n.py`. Se utilizó el modelo preentrenado `yolov8n.pt` como punto de partida, con pesos iniciales entrenados sobre COCO. Esta decisión permitió aprovechar características visuales generales previamente aprendidas y adaptar el modelo al dominio aéreo mediante ajuste fino.

El entrenamiento se realizó durante 100 épocas, con tamaño de imagen de 1280 píxeles y batch de 4 imágenes. La resolución de 1280 se seleccionó debido a la alta proporción de objetos pequeños identificada en el análisis exploratorio. El batch se mantuvo reducido por las limitaciones de memoria de la GPU utilizada. Se empleó el optimizador AdamW, una tasa de aprendizaje inicial de 0.001, *weight decay* de 0.0005 y entrenamiento con precisión mixta FP16 para reducir el consumo de memoria.

También se aplicaron técnicas de aumento de datos. Entre ellas se incluyeron $mosaic=1.0$, $mixup=0.15$, variaciones HSV, escalado, traslación y volteo horizontal. Se configuró $close_mosaic=10$ para desactivar el mosaico durante las últimas épocas y afinar el modelo con imágenes más cercanas a la distribución real de inferencia. Estas transformaciones se configuraron directamente en el script de entrenamiento y fueron utilizadas para incrementar la variabilidad visual del conjunto, simular cambios de escala y mejorar la robustez ante escenas densas. No obstante, se considera que estas técnicas no resuelven el desbalance de clases, por lo que el análisis por categoría se mantiene como parte central de la evaluación.

4.9 Evaluación del modelo YOLOv8n

El entrenamiento principal generó una carpeta de resultados en `runs/yolov8n/yolov8n_mosaic10_20260606_0315/`. En esta carpeta se almacenaron los pesos del modelo, las curvas de entrenamiento, las matrices de confusión, las curvas precisión-recall, las curvas F1, las predicciones sobre validación y el resumen de métricas finales en `metrics_summary.json`. De manera auxiliar, se realizó una corrida con $mosaic=0.5$ en `runs/yolov8n/yolov8n_MOSAIC05_20260606_1220/`, utilizada para justificar empíricamente la conservación de $mosaic=1.0$ como configuración principal.

La evaluación se realizó con las métricas estándar de detección utilizadas por Ultralytics: $mAP@0.5$, $mAP@0.5:0.95$, precisión y recall. Además, se calculó F1-score a partir de precisión y recall, y se registraron parámetros y GFLOPs mediante `model.info()`. También se analizaron métricas por clase para identificar diferencias de desempeño entre categorías frecuentes y minoritarias. Esta evaluación permitió observar que la clase *car* obtuvo el mejor desempeño, mientras que clases como *awning-tricycle*, *tricycle* y *bicycle* presentaron mayores dificultades.

Además de la precisión del modelo, se registró una medición preliminar de eficiencia en una GPU NVIDIA GeForce RTX 4050 Laptop mediante el script `src/evaluation/efficiency_profiling.py`. El protocolo de medición utilizó el split de prueba definido en `configs/visdrone.yaml`, inferencia con `batch=1`, tamaño de imagen de 1280 píxeles y una etapa de calentamiento antes de cronometrar. Esta medición permitió obtener una primera referencia del potencial de YOLOv8n para aplicaciones en tiempo real. Sin embargo, la eficiencia deberá medirse nuevamente en la plataforma objetivo, la NVIDIA Jetson Orin Nano, ya que el rendimiento en una GPU de laptop no representa directamente el comportamiento en hardware embebido.

4.10 Etapas pendientes de desarrollo

Aunque ya se completó el análisis de datos, el preprocesamiento y el entrenamiento inicial de YOLOv8n, el proyecto aún conserva etapas pendientes. La primera corresponde al entrenamiento de RT-DETR sobre VisDrone, con una configuración adecuada para la memoria disponible. Este modelo permitirá comparar una arquitectura ligera basada en YOLO contra una arquitectura híbrida CNN-Transformer.

Posteriormente, se realizará la validación cruzada sobre UAVDT. Esta evaluación permitirá analizar la capacidad de generalización del modelo entrenado en VisDrone hacia un dominio aéreo distinto. Para ello se observará la degradación de métricas en las clases compartidas entre ambos conjuntos: *car*, *truck* y *bus*.

También se integrará un módulo de seguimiento multiobjeto bajo el enfoque *tracking-by-detection*. En esta etapa se evaluarán métodos como DeepSORT o ByteTrack para asociar detecciones entre cuadros consecutivos, mantener identificadores de trayectoria y reducir pérdidas temporales de objetos. La evaluación del seguimiento se realizará con métricas como MOTA e IDF1.

Finalmente, se contempla el despliegue del modelo en una NVIDIA Jetson Orin Nano mediante TensorRT FP16. Esta etapa permitirá medir FPS y latencia en la plataforma objetivo, y evaluar si el sistema puede operar en condiciones cercanas a una aplicación real con UAV.

4.11 Consideraciones de reproducibilidad

Para garantizar la reproducibilidad del proyecto, las rutas de los conjuntos de datos se definieron mediante archivos de configuración YAML y no mediante rutas absolutas dentro del código. El archivo `configs/visdrone.yaml` define las rutas de imágenes, etiquetas y nombres de clases de VisDrone, mientras que `configs/uavdt.yaml` hace lo propio para UAVDT.

Los notebooks se utilizaron únicamente para exploración, análisis y visualización, mientras que el código reutilizable se colocó en la carpeta `src/`. Los resultados visuales y tabulares relevantes se almacenaron en `results/`, mientras que los archivos generados por entrenamiento se guardaron en `runs/`. Esta separación permite distinguir entre código fuente, análisis exploratorio, resultados documentables y salidas experimentales de entrenamiento.

En conjunto, la metodología aplicada hasta esta fase permitió construir una base experimental reproducible para el sistema de detección aérea. Las etapas ya ejecutadas proporcionan evidencia suficiente para analizar el comportamiento inicial de YOLOv8n, mientras que las etapas pendientes permitirán completar la comparación con RT-DETR, incorporar seguimiento temporal y evaluar la viabilidad de despliegue en hardware embebido.

Capítulo 5

Resultados

En este capítulo se presentan los resultados obtenidos hasta la fase actual del proyecto. Los resultados corresponden al análisis exploratorio del conjunto VisDrone-DET2019, la verificación del preprocesamiento de etiquetas, la caracterización preliminar de UAVDT, el entrenamiento actualizado de YOLOv8n sobre VisDrone, la comparación auxiliar de configuraciones *mosaic* y la medición preliminar de eficiencia en GPU RTX 4050. Las etapas de entrenamiento completo con RT-DETR, seguimiento multiobjeto, validación cruzada completa con UAVDT y despliegue en Jetson Orin Nano se mantienen como trabajo posterior dentro del desarrollo del sistema.

5.1 Resultados del análisis exploratorio de VisDrone

El conjunto VisDrone-DET2019 utilizado para el entrenamiento contiene 343,171 detecciones válidas distribuidas en diez clases. La Figura 2 muestra un desbalance marcado entre categorías, donde la clase *car* concentra 144,865 instancias, equivalente al 42.21% del total, mientras que clases como *awning-tricycle*, *tricycle* y *bus* presentan una representación mucho menor.




Figura 2: Distribución de clases en VisDrone-DET2019.

La Figura 2 permite observar que el conjunto VisDrone presenta un desbalance de clases considerable. La clase *car* es la más frecuente, con 144,865 detecciones,

seguida por *pedestrian* con 79,335 detecciones. En contraste, clases como *awning-tricycle*, *tricycle* y *bus* tienen una cantidad mucho menor de ejemplos.

Este comportamiento es importante porque durante el entrenamiento el modelo recibe más ejemplos de las clases dominantes, por lo que tiende a aprenderlas con mayor facilidad. Por el contrario, las clases con baja representación pueden obtener menor desempeño, ya que el modelo observa menos variaciones visuales de ellas. Esta diferencia ayuda a explicar por qué, en los resultados posteriores, la clase *car* obtiene el mejor mAP, mientras que *awning-tricycle* y *bicycle* presentan mayores dificultades.

Además, el análisis por tamaño de caja delimitadora mostró que el 60.47% de las instancias pertenece a la categoría *small* bajo el criterio COCO, el 34.00% corresponde a objetos medianos y únicamente el 5.53% a objetos grandes. Este resultado confirma que la detección de objetos pequeños representa uno de los principales retos del proyecto.




Figura 3: Distribución de objetos por tamaño según el criterio COCO.

La Figura 3 clasifica las detecciones de acuerdo con el tamaño de las cajas delimitadoras bajo el criterio COCO. Se observa que el 60.47% de los objetos pertenece a la categoría *small*, es decir, objetos que ocupan una región reducida dentro de la imagen. El 34.00% corresponde a objetos medianos y solo el 5.53% a objetos grandes.

Este resultado confirma que la detección de objetos pequeños es uno de los principales retos del proyecto. En imágenes aéreas, los objetos suelen ocupar pocos píxeles debido a la altura de captura del UAV. Por esta razón, se decidió entrenar con un tamaño de imagen de 1280 píxeles, con el objetivo de conservar más información visual durante el proceso de entrenamiento.

5.2 Densidad y dificultad de las escenas

La densidad de objetos por imagen también representa una dificultad relevante. El conjunto presenta una media de 53 objetos por imagen y una mediana de 42 objetos. Además, el 40.56% de las imágenes pertenece al nivel de densidad muy alta, con más de 50 objetos por imagen.




Figura 4: Densidad de objetos por imagen en VisDrone-DET2019.

La Figura 4 muestra la distribución de la cantidad de objetos por imagen. La media es de 53 objetos por imagen y la mediana es de 42, lo cual indica que muchas escenas contienen una cantidad elevada de instancias. Además, la distribución presenta una cola larga hacia la derecha, lo que significa que existen imágenes con una densidad mucho mayor al promedio.

Esta característica aumenta la dificultad del problema, ya que el modelo debe detectar múltiples objetos dentro de una misma escena, muchos de ellos pequeños, cercanos entre sí o parcialmente ocluidos. En consecuencia, el detector puede presentar falsos negativos cuando los objetos están muy juntos o falsos positivos cuando el fondo visual es complejo.



Figura 5: Ejemplo de escena densa con objetos pequeños en VisDrone.

La Figura 5 presenta un acercamiento a una de las imágenes más densas del conjunto, con 902 objetos anotados. En la parte izquierda se observa la región sin anotaciones y en la parte derecha se muestran las cajas delimitadoras correspondientes. Esta comparación permite notar que muchos objetos son visualmente difíciles de distinguir incluso para un observador humano, debido a su tamaño reducido y a la alta concentración de instancias.

Este ejemplo evidencia por qué la detección desde perspectiva aérea no puede tratarse como una detección convencional. La escena contiene objetos pequeños, cercanos entre sí y distribuidos en un fondo amplio, lo que exige que el modelo conserve información espacial fina. Por ello, el uso de mayor resolución de entrada y técnicas de aumento de datos resulta relevante para mejorar la robustez del detector.




Figura 6: Distribución de dificultad combinada por truncamiento y oclusión en VisDrone.

La Figura 6 resume las condiciones de dificultad relacionadas con truncamiento y oclusión. Se observa que 170,978 detecciones, equivalentes al 49.82%, presentan únicamente oclusión, mientras que 158,822 detecciones, equivalentes al 46.28%, no presentan problemas de truncamiento ni oclusión. También existen casos con solo truncamiento y casos donde ambos problemas aparecen simultáneamente.

La oclusión es especialmente relevante para este proyecto porque puede ocultar partes importantes del objeto y reducir la información visual disponible para el modelo. Esto puede provocar confusiones entre clases visualmente similares, como *pedestrian* y *people*, o entre vehículos pequeños como *bicycle*, *motor* y *tricycle*. Por tanto, esta figura ayuda a explicar por qué algunas clases presentan menor precisión o menor recall durante la evaluación.

5.3 Verificación del preprocesamiento

Después de convertir las etiquetas originales de VisDrone al formato YOLO normalizado, se realizó una verificación visual sobre imágenes del conjunto. La Figura 7 muestra que las cajas delimitadoras convertidas se alinean correctamente con los objetos presentes en la escena.

La Figura 7 muestra la verificación visual de las etiquetas después de convertirlas del formato original de VisDrone al formato YOLO normalizado. En las imágenes se observan las cajas delimitadoras y sus clases correspondientes superpuestas sobre los objetos.

Esta verificación es fundamental porque el entrenamiento depende directamente de la calidad de las etiquetas. Si las cajas estuvieran desplazadas, mal escaladas o asociadas a clases incorrectas, el modelo aprendería patrones erróneos. Al comprobar visualmente que las cajas coinciden con los objetos, se valida que el proceso de conversión fue adecuado y que los datos están listos para ser utilizados en el entrenamiento.




Figura 7: Verificación visual de etiquetas convertidas al formato YOLO.

5.4 Entrenamiento de YOLOv8n

Se entrenó YOLOv8n sobre VisDrone-DET2019 durante 100 épocas, utilizando pesos preentrenados en COCO. El entrenamiento se realizó con tamaño de imagen de 1280 píxeles, lote de 4 imágenes, optimizador AdamW, aumento de datos y precisión mixta FP16. La Tabla 5 resume la configuración experimental final utilizada en la corrida principal `runs/yolov8n/yolov8n_mosaic10_20260606_0315/`.

Los resultados de la Tabla 6 muestran que YOLOv8n alcanzó un $mAP@0.5$ de 0.4755 y un $mAP@0.5:0.95$ de 0.2874. La diferencia entre ambas métricas es esperada, ya que $mAP@0.5$ utiliza un umbral de IoU menos estricto, mientras que $mAP@0.5:0.95$ evalúa el desempeño en múltiples umbrales de localización, desde 0.5 hasta 0.95. Por esta razón, $mAP@0.5:0.95$ suele ser menor y refleja de forma más exigente la calidad de las cajas delimitadoras predichas.

La precisión obtenida fue de 0.5944, mientras que el recall fue de 0.4641, con un F1-score de 0.5212. Esto indica que el modelo tiende a ser moderadamente conservador: una proporción importante de sus detecciones son correctas, pero todavía

Tabla 5: Configuración experimental del entrenamiento de YOLOv8n.

Parámetro	Valor
Modelo base	YOLOv8n
Pesos iniciales	COCO
Épocas	100
Tamaño de imagen	1280
Batch	4
Optimizador	AdamW
Learning rate inicial	0.001
Weight decay	0.0005
Precisión mixta	FP16
Mosaic	1.0
Close mosaic	10
Mixup	0.15
Seed	0

Tabla 6: Métricas globales obtenidas por YOLOv8n en VisDrone.

Métrica	Valor
mAP@0.5	0.4755
mAP@0.5:0.95	0.2874
Precisión	0.5944
Recall	0.4641
F1-score	0.5212
Parámetros	3.01 M
GFLOPs	8.20

deja sin detectar algunos objetos presentes en las imágenes. Este comportamiento puede explicarse por las características del conjunto VisDrone, donde predominan objetos pequeños, escenas densas, oclusiones parciales y un fuerte desbalance de clases.

En particular, el análisis exploratorio mostró que el 60.47% de las instancias corresponde a objetos pequeños y que muchas imágenes contienen decenas de objetos por escena. Estas condiciones dificultan tanto la localización precisa de las cajas como la identificación correcta de las clases. Además, YOLOv8n es una arquitectura ligera, con aproximadamente 3.01 millones de parámetros y 8.20 GFLOPs, diseñada para priorizar eficiencia computacional, por lo que sus resultados representan un compromiso entre precisión y velocidad de inferencia.

Tabla 7: Comparación auxiliar de configuraciones *mosaic* en YOLOv8n.

Configuración	mAP@0.5	mAP@0.5:0.95	Precisión	F1	Interpretación
<i>mosaic</i> =1.0	0.4755	0.2874	0.5944	0.5212	Configuración final; mejor equilibrio observado.
<i>mosaic</i> =0.5	0.4708	0.2861	0.5721	0.5117	Experimento auxiliar; no superó a <i>mosaic</i> =1.0.

La Tabla 7 muestra que reducir *mosaic* de 1.0 a 0.5 no mejoró el desempeño global. La hipótesis del experimento auxiliar era que una menor intensidad de mosaico podría conservar más detalle en objetos pequeños; sin embargo, las métricas disminuyeron ligeramente. Por ello, se conserva *mosaic*=1.0 como configuración final, junto con *close_mosaic*=10 para afinar las últimas épocas con imágenes sin mosaico.




Figura 8: Curvas de entrenamiento y validación de YOLOv8n sobre VisDrone.

La Figura 8 presenta las curvas de entrenamiento y validación generadas durante las 100 épocas. En las gráficas de pérdida se observa una disminución progresiva de *box loss*, *classification loss* y *DFL loss*, lo que indica que el modelo fue mejorando tanto en localización de cajas como en clasificación de objetos.

Las métricas de precisión, recall, mAP@0.5 y mAP@0.5:0.95 muestran una tendencia creciente durante el entrenamiento. Hacia las últimas épocas, las curvas

comienzan a estabilizarse, lo que sugiere que el modelo alcanzó una zona de convergencia. Además, el uso de *close_mosaic*=10 permitió que el ajuste final se realizara con imágenes sin composición mosaico, acercando el entrenamiento de las últimas épocas a la distribución de inferencia.

5.5 Desempeño por clase

El mejor desempeño se obtuvo en la clase *car*, lo cual se relaciona con su alta representación en el conjunto de entrenamiento. En contraste, clases minoritarias y visualmente pequeñas, como *awning-tricycle*, *tricycle* y *bicycle*, obtuvieron valores más bajos.




Figura 9: Curva precisión-recall por clase para YOLOv8n.

La Figura 9 muestra la curva precisión-recall por clase. Esta gráfica permite analizar el comportamiento del detector al variar el umbral de confianza. Las clases con curvas más cercanas a la esquina superior derecha presentan mejor desempeño, ya que mantienen alta precisión y alto recall de forma simultánea.

La clase *car* obtiene el mejor desempeño, lo que coincide con su alta representación dentro del conjunto de entrenamiento. También se observan resultados aceptables en clases como *bus*, *motor* y *pedestrian*. En cambio, *awning-tricycle*, *tricycle* y *bicycle* presentan curvas más bajas, lo que refleja mayor dificultad para detectarlas correctamente. Esto puede explicarse por su baja frecuencia, tamaño reducido y similitud visual con otras clases.

La Figura 10 complementa la curva precisión-recall al mostrar el equilibrio entre detecciones correctas y objetos recuperados por clase. Esta figura es útil para analizar el efecto del desbalance, ya que las clases con menor frecuencia y mayor dificultad visual tienden a presentar valores F1 más bajos.




Figura 10: Curva F1 por clase para YOLOv8n.

5.6 Matriz de confusión

La Figura 11 muestra la matriz de confusión normalizada. La diagonal principal representa las detecciones clasificadas correctamente, mientras que los valores fuera de la diagonal indican confusiones entre clases. Se observa que la clase *car* presenta el valor más alto en la diagonal, lo que confirma que es la clase mejor aprendida por el modelo.

También se observan confusiones entre clases visualmente cercanas. Por ejemplo, *pedestrian* y *people* pueden confundirse porque ambas corresponden a personas vistas desde perspectiva aérea. De forma similar, *bicycle*, *motor*, *tricycle* y *awning-tricycle* pueden compartir formas pequeñas y alargadas, lo cual dificulta su separación. La presencia de valores asociados a *background* indica casos donde el modelo no detectó objetos reales o generó detecciones incorrectas sobre el fondo.




Figura 11: Matriz de confusión normalizada de YOLOv8n sobre VisDrone.

5.7 Eficiencia computacional preliminar

Además de las métricas de detección, se registró la eficiencia de inferencia del modelo YOLOv8n en una GPU NVIDIA GeForce RTX 4050 Laptop. La medición se realizó sobre 1,610 imágenes del split de prueba, con tamaño de imagen de 1280 píxeles, inferencia imagen por imagen y una etapa de calentamiento antes del registro de tiempos. Este resultado es preliminar, ya que la velocidad final deberá medirse posteriormente en la NVIDIA Jetson Orin Nano con TensorRT FP16.

Tabla 8: Eficiencia preliminar de YOLOv8n en GPU RTX 4050 Laptop.

Métrica	Valor
Imágenes evaluadas	1,610
Tamaño de imagen	1280
Latencia promedio	4.41 ms/img
FPS aproximados	226.58 FPS
VRAM	72.8 MB
RAM	1201.8 MB

La Tabla 8 muestra que YOLOv8n conserva una velocidad de inferencia alta en la GPU utilizada como referencia local. Sin embargo, estas métricas dependen directamente del hardware, por lo que no deben interpretarse como rendimiento final en UAV. La medición definitiva deberá repetirse en la Jetson Orin Nano, donde se evaluará el efecto de TensorRT FP16 y las restricciones reales de memoria y cómputo.

5.8 Caracterización preliminar de UAVDT

Como parte de la validación cruzada futura, se realizó una caracterización inicial del conjunto UAVDT. Este conjunto contiene tres clases compartidas con VisDrone: *car*, *truck* y *bus*. La distribución observada muestra un desbalance mayor que en VisDrone, ya que la clase *car* representa el 96.25% de las detecciones, mientras que *bus* y *truck* representan el 2.94% y 0.81%, respectivamente.

Tabla 9: Distribución preliminar de clases en UAVDT.

Clase	Detecciones	Porcentaje
car	33,694	96.25%
bus	1,030	2.94%
truck	283	0.81%

Estos resultados indican que UAVDT será útil para evaluar el cambio de dominio, pero también introduce un reto adicional debido al fuerte desbalance entre clases. Por esta razón, la evaluación sobre UAVDT deberá interpretarse como una prueba de generalización en un dominio aéreo distinto, no como una continuación directa del entrenamiento sobre VisDrone.

5.9 Síntesis de resultados actuales

Los resultados obtenidos muestran que YOLOv8n logra un desempeño funcional en detección aérea, especialmente en clases con mayor representación como *car*. Sin embargo, el desempeño disminuye en clases minoritarias, objetos pequeños y escenas densas, lo cual coincide con los hallazgos del análisis exploratorio. La presencia de oclusión, la alta densidad de objetos y el desbalance de clases explican parte de las diferencias observadas entre categorías.

En términos de eficiencia, YOLOv8n presentó una latencia preliminar de 4.41 ms por imagen, equivalente a 226.58 FPS en una GPU NVIDIA GeForce RTX 4050 Laptop. Este resultado sugiere potencial para aplicaciones en tiempo real dentro del entorno de referencia utilizado. No obstante, esta medición deberá repetirse en la Jetson Orin Nano, ya que el rendimiento en GPU de laptop no representa directamente el comportamiento en una plataforma embebida.

En conjunto, estos resultados justifican la comparación posterior con RT-DETR, la validación cruzada sobre UAVDT y la integración de estrategias de seguimiento temporal para mejorar la consistencia en secuencias de video.

5.10 Discusión final respecto al cronograma

De acuerdo con el cronograma de actividades, el proyecto se encuentra actualmente en transición entre la Actividad 3 y la Actividad 4. La Actividad 2 ya fue completada, ya que se realizó el análisis exploratorio de VisDrone y UAVDT mediante tablas y figuras de distribución de clases, desbalance, densidad de objetos, tamaños de caja, resoluciones, truncamiento y oclusión.

La Actividad 3 también presenta avances completados en sus componentes principales: conversión de etiquetas originales de VisDrone al formato YOLO normalizado, verificación visual de cajas delimitadoras y configuración de técnicas de aumento de datos como *mosaic*, *mixup*, variaciones HSV, escalado, traslación y volteo horizontal.

Asimismo, se inició la Actividad 4, correspondiente a la implementación y entrenamiento de modelos de detección. Hasta esta etapa se completó el entrenamiento de YOLOv8n sobre VisDrone-DET2019 durante 100 épocas, con métricas globales, F1-score, parámetros, GFLOPs, métricas por clase, curvas de entrenamiento, matriz de confusión y mediciones preliminares de eficiencia. Sin embargo, esta actividad aún no se considera finalizada porque falta entrenar y evaluar RT-DETR.

Por lo tanto, el avance actual puede resumirse como: Actividad 2 completada, Actividad 3 completada en la parte de preprocesamiento y aumento de datos, y Actividad 4 en desarrollo. Las actividades relacionadas con seguimiento multiobjeto, comparación completa, validación cruzada, integración del pipeline y preparación final permanecen pendientes dentro del cronograma.

5.11 Cronograma de Actividades

Tabla 10: Cronograma de actividades y estado de avance

No.	Actividad	FEB	MAR	ABR	MAY	JUN	JUL	AGO	SEP	OCT	NOV	DIC
1	Escritura del documento terminal (redacción, revisión y ajuste de secciones)	•	•	•	•	•	•	•	•	•	•	•
2	Análisis exploratorio de los conjuntos de datos VisDrone y UAVDT (distribución de clases, desbalance, densidad y tamaños de objeto)		✓	✓								
3	Preprocesamiento y aumento de datos (normalización de imágenes y etiquetas, transformaciones geométricas, ajustes fotométricos, <i>mosaic</i> y <i>mixup</i>)				✓	✓						
4	Implementación y entrenamiento de YOLOv8n y RT-DETR sobre VisDrone (ajuste de hiperparámetros y evaluación con mAP@0.5, mAP@0.5:0.95, precisión, recall, F1-score, IoU, GFLOPs y eficiencia)					•						
5	Desarrollo e integración del módulo de seguimiento temporal (DeepSORT / ByteTrack) y evaluación con métricas MOT (MOTA e IDF1)											
6	Comparación del <i>trade-off</i> precisión/eficiencia computacional (FPS, latencia) entre YOLOv8n y RT-DETR											
7	Validación cruzada sobre UAVDT y análisis de <i>domain shift</i>											
8	Integración del pipeline completo y generación de registros estructurados de eventos											
9	Ajustes finales, revisión integral del sistema y preparación de la presentación de resultados											

Simbología: ✓ actividad completada, • actividad en desarrollo, actividad programada o pendiente.

Capítulo 6

Conclusiones

A partir del desarrollo realizado hasta la fase actual del trabajo terminal, se concluye que la detección de objetos desde perspectiva aérea representa un problema complejo debido a las condiciones propias de las imágenes capturadas por UAV. El análisis exploratorio de VisDrone-DET2019 permitió confirmar la presencia de retos importantes, como el desbalance de clases, la alta proporción de objetos pequeños, la elevada densidad de instancias por imagen, la oclusión y el truncamiento. Estos factores justifican la necesidad de evaluar los modelos no solo mediante métricas globales, sino también mediante análisis por clase y mediciones de eficiencia computacional.

El análisis de los datos mostró que la clase *car* domina ampliamente el conjunto de entrenamiento, mientras que clases como *awning-tricycle*, *tricycle* y *bus* tienen una menor representación. Asimismo, se identificó que el 60.47% de las detecciones corresponde a objetos pequeños bajo el criterio COCO. Este hallazgo es relevante porque explica parte de la dificultad del problema y fundamenta decisiones metodológicas como el uso de imágenes de 1280 píxeles durante el entrenamiento. También permite concluir que el desbalance debe tratarse como un eje de análisis y no como un problema que pueda resolverse únicamente mediante aumento de datos.

La conversión de etiquetas del formato original de VisDrone al formato YOLO fue una etapa fundamental del proyecto. La verificación visual permitió comprobar que las cajas delimitadoras convertidas se alinean correctamente con los objetos presentes en las imágenes. Esto garantiza que el entrenamiento se realice con anotaciones consistentes y reduce el riesgo de que el modelo aprenda patrones incorrectos debido a errores de preprocesamiento.

En cuanto al entrenamiento de YOLOv8n, la configuración final con *mosaic*=1.0, *close_mosaic*=10, tamaño de imagen de 1280 píxeles, batch de 4, optimizador AdamW y semilla de reproducibilidad igual a 0 logró un desempeño funcional sobre VisDrone. El modelo alcanzó un mAP@0.5 de 0.4755, un mAP@0.5:0.95 de 0.2874, una precisión de 0.5944, un recall de 0.4641 y un F1-score de 0.5212. Además, cuenta con aproximadamente 3.01 millones de parámetros y 8.20 GFLOPs. Estos resultados muestran que una arquitectura ligera puede aprender patrones útiles en imágenes aéreas, aunque su desempeño se ve limitado por la presencia de objetos pequeños, clases minoritarias y escenas densas.

El experimento auxiliar con *mosaic*=0.5 permitió evaluar si una menor intensidad de mosaico mejoraba la detección de objetos pequeños. Sin embargo, esta configuración no superó a *mosaic*=1.0, ya que obtuvo métricas ligeramente menores. Por ello, se conserva *mosaic*=1.0 como configuración principal. Esta decisión se sus-

tenta en evidencia experimental y no únicamente en una suposición sobre el efecto del aumento de datos.

La eficiencia preliminar de YOLOv8n fue favorable en la GPU NVIDIA GeForce RTX 4050 Laptop, con una latencia promedio de 4.41 ms por imagen, equivalente a 226.58 FPS, un consumo aproximado de 72.8 MB de VRAM y 1201.8 MB de RAM. Esto indica que el modelo tiene potencial para aplicaciones en tiempo real. Sin embargo, este resultado debe interpretarse con precaución, ya que las métricas de eficiencia dependen del hardware y la medición final deberá realizarse en la plataforma objetivo, es decir, la NVIDIA Jetson Orin Nano con TensorRT FP16.

El aporte principal del trabajo no consiste en proponer una nueva arquitectura, sino en integrar un marco experimental reproducible para detección aérea que considera análisis de datos, preprocesamiento, entrenamiento, evaluación por clase, métricas de precisión, métricas de eficiencia, validación cruzada y preparación para seguimiento multiobjeto. Este alcance justifica la participación de dos integrantes, ya que el proyecto combina tareas de ciencia de datos, aprendizaje profundo, visión por computadora, evaluación experimental, eficiencia computacional y documentación técnica.

Entre las principales limitaciones de esta fase se encuentra que todavía no se ha completado el entrenamiento de RT-DETR, la evaluación cruzada completa sobre UAVDT ni la integración del módulo de seguimiento temporal. Por esta razón, los resultados actuales deben entenderse como una base experimental actualizada centrada en YOLOv8n y no como la comparación final entre arquitecturas.

Como trabajo posterior, se propone entrenar y evaluar RT-DETR sobre VisDrone bajo el mismo marco experimental para comparar su desempeño frente a YOLOv8n, especialmente en objetos pequeños y escenas densas. También será necesario realizar la validación cruzada sobre UAVDT para analizar el cambio de dominio, integrar algoritmos de seguimiento como DeepSORT o ByteTrack, y medir métricas multiobjeto como MOTA e IDF1. Finalmente, se deberá evaluar el rendimiento del sistema en la Jetson Orin Nano para determinar su viabilidad en un entorno embebido cercano a una aplicación real con UAV.

En conjunto, los avances obtenidos permiten establecer una base sólida para el desarrollo del sistema de detección y seguimiento de objetos desde perspectiva aérea. El trabajo realizado demuestra que el análisis de datos, el preprocesamiento correcto, la evaluación detallada por clase y la medición de eficiencia son etapas esenciales para comprender el comportamiento del modelo y orientar las siguientes fases del proyecto.

Referencias

- [1] Shaoqing Ren et al. “Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks”. In: *Advances in Neural Information Processing Systems*. Vol. 28. 2015.
- [2] Wei Liu et al. “SSD: Single Shot MultiBox Detector”. In: *Computer Vision – ECCV 2016*. Springer, 2016, pp. 21–37. DOI: [10.1007/978-3-319-46448-0_2](https://doi.org/10.1007/978-3-319-46448-0_2).
- [3] Joseph Redmon et al. “You Only Look Once: Unified, Real-Time Object Detection”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2016, pp. 779–788. DOI: [10.1109/CVPR.2016.91](https://doi.org/10.1109/CVPR.2016.91).
- [4] Yian Zhao et al. “DETRs Beat YOLOs on Real-Time Object Detection”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2024, pp. 16965–16974.
- [5] Guangyi Tang et al. “A Survey of Object Detection for UAVs Based on Deep Learning”. In: *Remote Sensing* 16.1 (2024), p. 149. DOI: [10.3390/rs16010149](https://doi.org/10.3390/rs16010149).
- [6] Wei Hua and Qili Chen. “A Survey of Small Object Detection Based on Deep Learning in Aerial Images”. In: *Artificial Intelligence Review* 58.6 (2025), p. 162. DOI: [10.1007/s10462-025-11150-9](https://doi.org/10.1007/s10462-025-11150-9).
- [7] Dawei Du et al. “VisDrone-DET2019: The Vision Meets Drone Object Detection in Image Challenge Results”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops*. 2019.
- [8] Dawei Du et al. “The Unmanned Aerial Vehicle Benchmark: Object Detection and Tracking”. In: *Proceedings of the European Conference on Computer Vision*. 2018, pp. 375–391.
- [9] Nicolai Wojke, Alex Bewley, and Dietrich Paulus. “Simple Online and Real-time Tracking with a Deep Association Metric”. In: *2017 IEEE International Conference on Image Processing*. 2017, pp. 3645–3649. DOI: [10.1109/ICIP.2017.8296962](https://doi.org/10.1109/ICIP.2017.8296962).
- [10] Yifu Zhang et al. “ByteTrack: Multi-Object Tracking by Associating Every Detection Box”. In: *Proceedings of the European Conference on Computer Vision*. 2022, pp. 1–17. DOI: [10.1007/978-3-031-20047-2_1](https://doi.org/10.1007/978-3-031-20047-2_1).
- [11] Alex Bewley et al. “Simple Online and Realtime Tracking”. In: *2016 IEEE International Conference on Image Processing*. 2016, pp. 3464–3468. DOI: [10.1109/ICIP.2016.7533003](https://doi.org/10.1109/ICIP.2016.7533003).
- [12] Dunja Bozic-Stulic et al. “Complete Model for Automatic Object Detection and Localisation on Aerial Images using Convolutional Neural Networks”. In: *Journal of Communications Software and Systems* 14.1 (2018), pp. 82–90. DOI: [10.24138/jcomss.v14i1.441](https://doi.org/10.24138/jcomss.v14i1.441).

- [13] Sasa Sambolek and Marina Ivasic-Kos. “Person Detection and Geolocation Estimation in UAV Aerial Images: An Experimental Approach”. In: *Proceedings of the 13th International Conference on Pattern Recognition Applications and Methods*. SciTePress, 2024, pp. 785–792. DOI: [10.5220/0012411600003654](https://doi.org/10.5220/0012411600003654).
- [14] Francesco Ciccone and Alessandro Ceruti. “Real-Time Search and Rescue with Drones: A Deep Learning Approach for Small-Object Detection Based on YOLO”. In: *Drones* 9.8 (2025), p. 514. DOI: [10.3390/drones9080514](https://doi.org/10.3390/drones9080514).
- [15] Oscar Ramirez-Ayala et al. “Real-Time Person Detection in Wooded Areas Using Thermal Images from an Aerial Perspective”. In: *Sensors* 23.22 (2023), p. 9216. DOI: [10.3390/s23229216](https://doi.org/10.3390/s23229216).